

# ML note

mstyoda 骆轩源

## Contents

<b>1</b>	<b>Rademacher Complexity and VC-Dimension</b>	<b>2</b>
1.1	Rademacher complexity . . . . .	2
1.2	Growth function . . . . .	5
1.3	VC-dimension . . . . .	8
<b>2</b>	<b>Boosting</b>	<b>12</b>
2.1	Introduction . . . . .	12
2.1.1	AdaBoost . . . . .	12
<b>3</b>	<b>On-Line Learning</b>	<b>16</b>
3.1	Introduction . . . . .	16
3.2	Prediction with expert advice . . . . .	16
3.2.1	Mistake bounds and Halving algorithm . . . . .	16
3.2.2	Weighted majority algorithm . . . . .	17
3.2.3	Randomized weighted majority algorithm . . . . .	19
<b>4</b>	<b>Dimensionality Reduction</b>	<b>22</b>
4.1	Principal Component Analysis . . . . .	22
4.1.1	奇异值分解(Singular Value Decomposition . . . . .	23
4.1.2	正交投影矩阵(orthogonal projection matrix): . . . . .	23
4.1.3	PCA . . . . .	23
4.2	Kernel Principal Component Analysis . . . . .	25
4.3	Johnson-Lindenstrauss lemma . . . . .	26

# 1 Rademacher Complexity and VC-Dimension

## 1.1 Rademacher complexity

Rademacher Complexity是用来衡量一个函数族 $G : X \rightarrow \mathbb{R}$ 的复杂程度的指标，它考验的是 $G$ 对于随机噪声的拟合能力。比如给定样本 $S = (z_1, z_2 \dots z_m)$ ，其中 $z_i = (x_i, y_i)$ ，那么先随机生成一个序列 $\sigma = (\sigma_1, \sigma_2 \dots \sigma_m)$ ，然后在 $G$ 中找到一个函数 $g$ ，使得 $\mathbf{g}(S) \cdot \sigma$ 最大，把这个值对于 $\sigma$ 求期望，就得到了Empirical Rademacher complexity。

**Definition 1.** 给定函数族 $G$ ，其中的函数将 $Z$ 映射到实数区间 $[a, b]$ ，并且给定一个大小为 $m$ 的 $S$ ， $\sigma_i$ 独立均匀分布在 $\{-1, 1\}$ 内，则定义 $G$ 对于 $S$ 的*Empirical Rademacher complexity*为：

$$\hat{\mathcal{R}}_S(G) = E_{\sigma} \left[ \sup_{g \in G} \frac{1}{m} \sum_{i=1}^m \sigma_i g(z_i) \right] \quad (1)$$

很自然地，如果我们不固定 $S$ ，只固定 $m$ ，让 $z_1, z_2 \dots z_m$ 独立同分布于 $D$ ，则可以定义 $G$ 对于样本大小为 $m$ 的Rademacher complexity为：

**Definition 2.** 给定函数族 $G$ ，其中的函数将 $Z$ 映射到实数区间 $[a, b]$ ，并且给定 $m$ ， $z_i$ 独立同分布 $D$ ， $\sigma_i$ 独立均匀分布在 $\{-1, 1\}$ 内，则定义 $G$ 对于 $S$ 的*Rademacher complexity*为：

$$\begin{aligned} \mathcal{R}_m(G) &= E_{S, \sigma} \left[ \sup_{g \in G} \frac{1}{m} \sum_{i=1}^m \sigma_i g(z_i) \right] \\ &= E_{S \sim D^m} [\hat{\mathcal{R}}_S(G)] \end{aligned} \quad (2)$$

那么我们研究函数族的复杂性有什么作用呢？它能够提供如下一个bound:

**Theorem 1.** 假如 $G$ 是一个函数族，其中的函数是从 $Z$ 到 $[0, 1]$ 区间的映射，那么对于任意 $\delta > 0$ ，至少有 $1 - \delta$ ，使得对于任意 $g \in G$ 满足：

$$E[g(z)] \leq \frac{1}{m} \sum_{i=1}^m g(z_i) + 2\mathcal{R}_m(G) + \sqrt{\frac{\log \frac{1}{\delta}}{2m}} \quad (3)$$

$$\text{and } E[g(z)] \leq \frac{1}{m} \sum_{i=1}^m g(z_i) + 2\hat{\mathcal{R}}_m(G) + 3\sqrt{\frac{\log \frac{2}{\delta}}{2m}} \quad (4)$$

在证明之前，我们先来看看这个定理想要表达的意思，根据PAC 那一章节的定义，Generalization error和Empirical error分别为：

$$R(h) = \Pr_{x \sim D}[h(x) \neq c(x)] = E_{x \sim D}[1_{h(x) \neq c(x)}] \quad (5)$$

$$\hat{R}(h) = \frac{1}{m} \sum_{i=1}^m 1_{h(x_i) \neq c(x_i)} \quad (6)$$

$R(h)$ 说的假设 $h$ 的错误率， $\hat{R}(h)$ 说的是假设 $h$ 在这 $m$  个测试样本上的错误率。那么回到我们刚才的定理，给定一个假设空间 $H$ （是一个函数族），我们可以将其转换到另一个函数族 $G$ ，对于任意 $g \in G$ ，其对应于某一个 $h \in H$ ，有 $g(z) = g(x, y) = L(h(x), y)$ ， $L$ 是损失函数loss function。在这里我们认为 $L$ 为0-1 loss，也即：

$$L(y', y) = \begin{cases} 1 & y' \neq y \\ 0 & y' = y \end{cases} \quad (7)$$

那么定理中左边的 $E[g(z)]$ 就对应于 $R(h)$ ，右边的 $\frac{1}{m} \sum_{i=1}^m g(z_i)$ 对应于 $\hat{R}(h)$ 。所以定理说的其实是：

$$R(h) \leq \hat{R}(h) + 2\mathcal{R}_m(G) + \sqrt{\frac{\log \frac{1}{\delta}}{2m}}$$

由于 $R(h)$ 是很难说明的，但是 $\hat{R}(h)$ 是可以实验得到的，该bound就能利用实验得出的结果来估算 $R(h)$ 的一个上界。注意到 $G$ 仅仅跟 $L$ 和 $H$ 有关，所以我们将 $2\mathcal{R}_m(G)$ 写成 $H$  的形式：（中间的推导基于 $\sigma_i$ 是均匀分布在 $\{-1, 1\}$ 的随机变量，所以 $E[\sigma_i] = 0$ ）

$$\begin{aligned} \hat{\mathcal{R}}_S(G) &= E_{\sigma} \left[ \sup_{g \in G} \frac{1}{m} \sum_{i=1}^m g(z_i) \sigma_i \right] \\ &= E_{\sigma} \left[ \sup_{g \in G} \frac{1}{m} \sum_{i=1}^m \frac{1 - h(x_i) y_i}{2} \sigma_i \right] \\ &= E_{\sigma} \left[ \sup_{g \in G} \frac{1}{m} \sum_{i=1}^m \frac{-h(x_i) y_i}{2} \sigma_i \right] \\ &= \frac{1}{2} E_{\sigma} \left[ \sup_{g \in G} \frac{1}{m} \sum_{i=1}^m h(x_i) \sigma_i \right] = \frac{1}{2} \hat{\mathcal{R}}_{SX}(H) \end{aligned} \quad (8)$$

最后一步推导是因为，当 $y_i$ 只能是1或-1，所以 $-y_i \sigma_i$ 也是在 $\{-1, 1\}$ 之间的均匀分布，和 $\sigma_i$ 同分布，所以可以替换。由如上结论可以得到：

$$\mathcal{R}_m(G) = E_{S \sim D^m} [\hat{\mathcal{R}}_S(G)] = \frac{1}{2} \mathcal{R}_m(H) \quad (9)$$

所以到这一步，之前的定理可以转化为：

$$R(h) \leq \hat{R}(h) + \mathcal{R}_m(H) + \sqrt{\frac{\log \frac{1}{\delta}}{2m}} \quad (10)$$

$$\text{and } R(h) \leq \hat{R}(h) + \hat{\mathcal{R}}_S(H) + 3\sqrt{\frac{\log \frac{2}{\delta}}{2m}} \quad (11)$$

下面给出Theorem 1的证明：

*Proof.* 令  $\Phi(S) = \sup_{g \in G} E[g(z)] - \frac{1}{m} \sum_{i=1}^m g(z_i)$ ，它描述的是，相减的两个东西的差距的上界，也即求出  $\Phi(S)$  就可以完成证明，则对于任意  $S'$ ，如果  $S'$  与  $S$  仅有 1 个  $z_k$  不同，那么有：

$$\Phi(S) - \Phi(S') = \sup_{g \in G} \frac{1}{m} g(z'_k) - g(z_k) \leq \frac{1}{m} \quad (12)$$

由对称性可以知道， $\Phi(S') - \Phi(S) \leq \frac{1}{m}$ ，这时候使用 McDiarmid's inequality (之后证明)，可以得到，对于任意  $\delta > 0$ ，至少有  $1 - \delta/2$  的概率满足：

$$\Phi(S) \leq E_S[\Phi(S)] + \sqrt{\frac{\log \frac{2}{\delta}}{2m}} \quad (13)$$

如果  $E_S[\Phi(S)]$  是一个比较稳定的值，那么该不等式也即说明了随着样本数目  $m$  的增加，二者的差距在  $1 - \delta/2$  的信心下的误差上界以根号的速度减小，接下来研究  $E_S[\Phi(S)]$  的上界：

$$\begin{aligned} E_S[\Phi(S)] &= E_S\left[\sup_{g \in G} E[g(z)] - \frac{1}{m} \sum_{i=1}^m g(z_i)\right] \\ &= E_S\left[\sup_{g \in G} E_{S'}[\hat{E}_{S'}[g(z)]] - \hat{E}_S[g(z)]\right] \\ &= E_S\left[\sup_{g \in G} E_{S'}[\hat{E}_{S'}[g(z)] - \hat{E}_S[g(z)]]\right] \\ &\leq E_{S,S'}\left[\sup_{g \in G} (\hat{E}_{S'}[g(z)] - \hat{E}_S[g(z)])\right] \end{aligned} \quad (14)$$

最后一步用到了  $\sup_x E_y[f(x, y)] \leq E_y[\sup_x f(x, y)]$ 。

考虑到  $\sigma_i$  等概率取自 1 或 -1，由于  $S$  和  $S'$  均为随机变量，当  $\sigma_i$  给定时，根据对称性有  $E_{S,S'} \sigma_i(g(z_i) - g(z'_i)) = E_{S,S'}(g(z_i) - g(z'_i))$ ，那么也就有：

$$\begin{aligned} \text{上式} &= E_{\sigma,S,S'}\left[\sup_{g \in G} \frac{1}{m} \sum_{i=1}^m \sigma_i(g(z_i) - g(z'_i))\right] \\ &= E_{\sigma,S}\left[\sup_{g \in G} \frac{1}{m} \sum_{i=1}^m \sigma_i(g(z_i))\right] + E_{\sigma,S'}\left[\sup_{g \in G} \frac{1}{m} \sum_{i=1}^m \sigma_i(g(z'_i))\right] \\ &= 2\mathcal{R}_m(G) \end{aligned} \quad (15)$$

综上所述，至少有  $1 - \delta/2$  的信心满足：

$$\begin{aligned}\Phi(S) &\leq E_S[\Phi(S)] + \sqrt{\frac{\log \frac{2}{\delta}}{2m}} \\ &\leq 2\mathcal{R}_m(G) + \sqrt{\frac{\log \frac{2}{\delta}}{2m}}\end{aligned}\tag{16}$$

又因为对于任意两个仅相差一个元素的  $S'$  和  $S$ ， $\hat{\mathcal{R}}_S(G) - \hat{\mathcal{R}}_{S'}(G) \leq \frac{1}{m}$ ，再一次使用 McDiarmid's inequality，可以知道至少有  $1 - \delta/2$  的信心满足：

$$E_S[\hat{\mathcal{R}}_S(G)] \leq \hat{\mathcal{R}}_S(G) + \sqrt{\frac{\log \frac{2}{\delta}}{2m}}\tag{17}$$

也即：

$$\mathcal{R}_m(G) \leq \hat{\mathcal{R}}_S(G) + \sqrt{\frac{\log \frac{2}{\delta}}{2m}}\tag{18}$$

使用 union bound 合并式上两个式子，可以至少有  $1 - \delta$  的概率满足：

$$\Phi(S) \leq 2\hat{\mathcal{R}}_S(G) + 3\sqrt{\frac{\log \frac{2}{\delta}}{2m}}\tag{19}$$

到此为止，该定理的两个不等式都得到了证明。  $\square$

由于  $\mathcal{R}_m(H)$  的计算涉及到随机变量和上确界，其计算非常困难，接下来我们引入其一个上界 growth function，它与随机变量无关，可计算性更强。

## 1.2 Growth function

首先引入 growth function 的定义，

**Definition 3.** 给定假设空间  $H$ ，和正整数  $m$ ，定义 growth function  $\Pi_H : \mathbb{N} \rightarrow \mathbb{N}$  为：

$$\Pi_H(m) = \max_{(x_1, x_2, \dots, x_m) \in \mathcal{X}} |\{(h(x_1), h(x_2), \dots, h(x_m)) | h \in H\}| \tag{20}$$

该函数定义的也是  $H$  的一个复杂性，给定  $m$  个点，用  $H$  中的函数去映射，能产生不超过  $|\Pi_H(m)|$  种结果，找到  $m$  个点，使得该结果数最多，此时的结果数就为  $\Pi_H(m)$ 。

接下来引入 Massart's lemma，它为 Rademacher complexity 和 growth function 搭了一个重要的桥梁：

**Theorem 2.** 设有限集合  $A \subseteq R^m$ , 令  $r = \max_{x \in A} \|x\|_2$ , 则有:

$$E_\sigma \left[ \frac{1}{m} \sup_{x \in A} \sum_{i=1}^m \sigma_i x_i \right] \leq \frac{r \sqrt{2 \log |A|}}{m} \quad (21)$$

其中  $\sigma_i$  独立均匀取自  $\{-1, 1\}$ 。

*Proof.* 定义随机变量  $Y = \sup_{x \in A} \sum_{i=1}^m \sigma_i x_i$ , 函数  $f(y) = \exp(t \cdot y)$ ,  $t > 0$ , 所以有:

$$f(E[Y]) \leq E[f(Y)] \quad (22)$$

这是因为对于任意  $\alpha_1, \alpha_2, \dots, \alpha_n > 0$  且  $\sum_i \alpha_i = 1$  时, 有: (下凸函数性质)

$$f(\alpha_1 y_1 + \alpha_2 y_2 + \dots + \alpha_n y_n) \leq \alpha_1 f(y_1) + \alpha_2 f(y_2) + \dots + \alpha_n f(y_n) \quad (23)$$

又因为,  $Y$  的取值最多只有  $2^m$  种, 故令  $n = 2^m$ ,  $y_1 \dots y_n$  分别对应每一种取值, 则有:

$$f(E[Y]) = f\left(\sum_{i=1}^n y_i \Pr[Y = y_i]\right) \leq \sum_{i=1}^n \Pr[Y = y_i] f(y_i) = E[f(Y)] \quad (24)$$

所以有,

$$\begin{aligned} \exp(t \cdot E[\sup_{x \in A} \sum_{i=1}^m \sigma_i x_i]) &\leq E[\exp(t \cdot \sup_{x \in A} \sum_{i=1}^m \sigma_i x_i)] \\ &= E[\sup_{x \in A} \exp(\sum_{i=1}^m t \cdot \sigma_i x_i)] \\ &\leq \sum_{x \in A} E[\exp(\sum_{i=1}^m t \cdot \sigma_i x_i)] \\ &= \sum_{x \in A} \prod_{i=1}^m E[\exp(t \sigma_i x_i)] \end{aligned} \quad (25)$$

上述推导用了求和来放缩  $\sup$ , 并且  $\sigma_i$  之间相互独立, 继续放缩右边的式子:

$$E[\exp(t \sigma_i x_i)] \leq \exp\left(\frac{t^2 (2r)^2}{8}\right) \quad (26)$$

这是因为  $\sigma_i x_i \in [-x_i, x_i]$ , 令  $a = -x_i, b = x_i$ , 由凸函数性质有:

$$\exp(t \sigma_i x_i) \leq \frac{b - \sigma_i x_i}{b - a} \exp(ta) + \frac{\sigma_i x_i - a}{b - a} \exp(tb) \quad (27)$$

两边取期望得到:

$$E[e^{t \sigma_i x_i}] \leq e^{ta} E\left[\frac{b - \sigma_i x_i}{b - a}\right] + e^{tb} E\left[\frac{\sigma_i x_i - a}{b - a}\right] \quad (28)$$

由于  $E[\sigma_i x_i] = 0$  所以上式子可以写成:

$$\begin{aligned} E[e^{t\sigma_i x_i}] &\leq e^{ta} \frac{b}{b-a} + e^{tb} \frac{-a}{b-a} \\ &\leq e^{\phi(t)} \end{aligned} \quad (29)$$

$$\begin{aligned} \phi(t) &= \log(e^{ta} \frac{b}{b-a} + e^{tb} \frac{-a}{b-a}) \\ &= ta + \log(\frac{b}{b-a} + e^{tb-ta} \frac{-a}{b-a}) \\ &= \phi(0) + t\phi'(0) + \frac{t^2}{2}\phi''(\theta) \\ &= t^2 \frac{(b-a)^2}{8} \end{aligned} \quad (30)$$

最后一步是暴力泰勒展开得到的, 所以得到:

$$E[e^{t\sigma_i x_i}] \leq \exp(t^2 \frac{(b-a)^2}{8}) = \exp(t^2 \frac{x_i^2}{2}) \quad (31)$$

$$\begin{aligned} \exp(t \cdot E[\sup_{x \in A} \sum_{i=1}^m \sigma_i x_i]) &\leq \sum_{x \in A} \exp(t^2 r^2 / 2) \\ &\leq |A| \exp(t^2 r^2 / 2) \end{aligned} \quad (32)$$

$$(t \cdot E[\sup_{x \in A} \sum_{i=1}^m \sigma_i x_i]) \leq (\frac{t^2 r^2}{2}) + \log |A| \quad (33)$$

$$E[\sup_{x \in A} \sum_{i=1}^m \sigma_i x_i] \leq (\frac{tr^2}{2}) + \frac{\log |A|}{t} \quad (34)$$

取  $t = \sqrt{\frac{2 \log |A|}{r^2}}$  可以得到右边最小值为  $\sqrt{2 \log |A|} r$ , 此时得到:

$$E[\sup_{x \in A} \sum_{i=1}^m \sigma_i x_i] \leq \sqrt{2 \log |A|} r \quad (35)$$

$$\frac{1}{m} E[\sup_{x \in A} \sum_{i=1}^m \sigma_i x_i] \leq \frac{r \sqrt{2 \log |A|}}{m} \quad (36)$$

定理得证。

□

我们尝试把 $\mathcal{R}_m(H)$ 和 $\Pi_H(m)$ 建立联系, 首先假设 $H$ 中的函数 $h$ 将点映射到 $\{-1, 1\}$ , 则:

$$\mathcal{R}_m(H) = E_{S \sim D^m} [E_{\sigma} [\sup_{h \in H} \frac{1}{m} \sum_{i=1}^m \sigma_i h(z_i)]] \quad (37)$$

使用Theorem2, 把 $H_S$ 看成 $A$ 可以得到:

$$\begin{aligned} \mathcal{R}_m(H) &\leq E_{S \sim D^m} [\frac{r \sqrt{2 \log |H_S|}}{m}] \\ &\leq \frac{r \sqrt{2 \log \Pi_H(m)}}{m} \end{aligned} \quad (38)$$

其中当 $S$ 给定时 $r = \max_{h \in H} \{\|(h(x_1), h(x_2), \dots, h(x_m))\|_2\}$ , 我们假设 $H$ 中的函数映射到 $\{-1, 1\}$ , 那么有 $r \leq \sqrt{m}$ 对任意 $S \sim D^m$ 成立。

所以在这种假定下, 上式可以写成:

$$\mathcal{R}_m(H) \leq \sqrt{\frac{2 \log \Pi_H(m)}{m}} \quad (39)$$

所以前一小节的bound可以被写为:

$$\begin{aligned} R(h) &\leq \hat{R}(h) + \mathcal{R}_m(H) + \sqrt{\frac{\log \frac{1}{\delta}}{2m}} \\ &\leq \hat{R}(h) + \sqrt{\frac{2 \log \Pi_H(m)}{m}} + \sqrt{\frac{\log \frac{1}{\delta}}{2m}} \end{aligned} \quad (40)$$

### 1.3 VC-dimension

前面提到的growth function虽然说不依赖于随机变量, 但是计算仍然相当困难, 接下来引入另外一个用来衡量假设空间 $H$ 的复杂性的指标, VC-dimension。它的定义如下:

**Definition 4.** 一个假设空间 $H$ 的VC-dimension被定义为, 最大的可能被 $H$ 完全打散的数据的大小, 也即:

$$VCdim(H) = \max\{m : \Pi_H(m) = 2^m\} \quad (41)$$

它的定义蕴含了两个意思:

1. 对于任意 $m \leq VCdim(H)$ , 存在一个 $S = (x_1, x_2, \dots, x_m)$ , 使得 $|H|_S| = 2^m$ 。
2. 对于任意 $m > VCdim(H)$ , 不存在 $S = (x_1, x_2, \dots, x_m)$ , 使得 $|H|_S| = 2^m$ 。



下面我们将 $VCdim(H)$ 和 $\Pi_H(m)$ 建立联系, 这样我们就可以将之前的bound用 $VCdim(H)$ 来表示。

首先引入一个定理:

**Theorem 3.** 设假设空间 $H$ 的 $VCdim(H) = d$ , 那么对于任意 $m \in \mathbb{N}$ , 有如下不等式成立:

$$\Pi_H(m) \leq \sum_{i=0}^d \binom{m}{i} \quad (42)$$

*Proof.* 对 $m + d$ 的大小归纳, 这么归纳的目的是为了用如下性质:

$$\binom{m}{i} = \binom{m-1}{i} + \binom{m-1}{i-1} \quad (43)$$

利用该性质我们可以得到:

$$\sum_{i=0}^d \binom{m-1}{i} + \sum_{i=0}^{d-1} \binom{m-1}{i} = \sum_{i=0}^d \binom{m}{i} \quad (44)$$

接下来我们按照两重循环求组合数的顺序(先枚举 $m$ , 再枚举 $d$ ) 来归纳证明:

1. 基础:  $m = 1$ 时,  $d = 0, d = 1$ 都有结论成立。
2. 归纳:  $m \geq 2$ 时, 若 $d = 0$ 则结论成立, 否则令 $S$ 为满足 $|H|_S| = \Pi_H(m)$  的一个Sample。令 $G$ 表示将 $H$ 约束到 $S$ 上的函数集合(将 $H$ 定义域改成 $S$ ), 有 $|G| = \Pi_H(m)$ 。

下面我们将 $G$ 分割成两个假设空间 $G_1$ 和 $G_2$ , 使得 $VCdim(G_1) \leq d, VCdim(G_2) \leq d - 1$ , 且有 $|G_1| \leq \Pi_{G_1}(m - 1), |G_2| \leq \Pi_{G_2}(m - 1)$ , 就能完成归纳:

先约定 $H : \mathcal{X} \rightarrow \{0, 1\}, S' = (x_1, x_2, \dots, x_{m-1})$ ,

那么令 $G_1$ 为将 $H$ 约束到 $S'$ 上的函数集合, 也就是在 $G$ 中只看前 $m - 1$  个点的分类结果来去重。

我们在 $G$ 中找到两个函数 $g_1, g_2$ , 使得它们约束到 $S'$ 上都是一样的, 那么有它们对 $x_m$ 的分类就一个是0, 一个是1。我们把分类是0的那个函数扔到 $G'_2$ 里。

我们将 $G$ 中的函数, 按照其在 $S'$ 的取值作为key,  $G$ 中每个key恰好在 $G_1$ 中出现一次,  $G$ 中每个出现2次的key都恰好在 $G'_2$ 出现一次。

所以有 $|G_1| + |G'_2| = |G|$ , 再让 $G_2$ 为将 $G'_2$ 约束到 $S'$ 的结果, 一定有 $|G_2| = |G'_2|$ , 故替换后有 $|G_1| + |G_2| = |G|$ 。

由于 $G_1, G_2$ ，考虑到 $G_1, G_2$ 大小都等于自己作用在 $S'$ 上的大小，由growth function定义有：

$$|G_1| \leq \Pi_{G_1}(m-1) \quad (45)$$

$$|G_2| \leq \Pi_{G_2}(m-1) \quad (46)$$

由于 $G_1 \subseteq H$ ，肯定有 $VCdim(G_1) \leq VCdim(H) = d$ ，又因为 $G_2$ 的定义域是 $S'$ ，我们假设其VCdim为 $k$ ，那么 $G_2$ 的极限也就是能把 $S_k \subseteq S'$ 中的元素全部打散，往 $S_k$ 中加入 $x_m$ ，这时 $H$ 就可以打散，但是 $G_2$ 不可以打散。所以有 $VCdim(G_2) \leq VCdim(H) - 1 = d - 1$ 。

所以有：

$$|G_1| \leq \Pi_{G_1}(m-1) \leq \sum_{i=0}^d \binom{m-1}{i} \quad (47)$$

$$|G_2| \leq \Pi_{G_2}(m-1) \leq \sum_{i=0}^{d-1} \binom{m-1}{i} \quad (48)$$

$$\Pi_H(m) = |G| = |G_1| + |G_2| \leq \sum_{i=0}^d \binom{m}{i} \quad (49)$$

□

然后我们把组合数求和变成一个容易求的上界，如果 $(m \geq d)$ ，

$$\begin{aligned} \Pi_H(m) &\leq \sum_{i=0}^d \binom{m}{i} \\ &\leq \sum_{i=0}^d \binom{m}{i} \left(\frac{m}{d}\right)^{d-i} \\ &\leq \sum_{i=0}^m \binom{m}{i} \left(\frac{m}{d}\right)^{d-i} \\ &= \left(\frac{m}{d}\right)^d \sum_{i=0}^m \binom{m}{i} \left(\frac{d}{m}\right)^i \\ &= \left(\frac{m}{d}\right)^d \left(1 + \frac{d}{m}\right)^m \\ &= \left(\frac{m}{d}\right)^d \left(1 + \frac{d}{m}\right)^{m/d \cdot d} \\ &\leq \left(\frac{em}{d}\right)^d \end{aligned} \quad (50)$$

推导中比较巧妙的地方在于，凭空加入 $(\frac{m}{d})^{d-i}$ 这一项，凑出来一个二项式求和，反向使用二项式定理，然后用自然对数 $e$ 的展开就很自然了。

到了这一步，我们可以将之前的bound改成，如果 $m \geq d$ ，对于某VCdim为 $d$ 的假设空间 $H$ ，有 $1 - \delta$ 的信心满足：

$$\begin{aligned} R(h) &\leq \hat{R}(h) + \sqrt{\frac{2 \log \Pi_H(m)}{m}} + \sqrt{\frac{\log \frac{1}{\delta}}{2m}} \\ &\leq \hat{R}(h) + \sqrt{\frac{2d \log(\frac{em}{d})}{m}} + \sqrt{\frac{\log \frac{1}{\delta}}{2m}} \\ &\leq \hat{R}(h) + O\left(\sqrt{\frac{\log(m/d)}{(m/d)}}\right) \end{aligned} \quad (51)$$

接下来介绍一个结论：

**Theorem 4.** 所有 $n$ 维的超平面分类函数构成的集合 $H_n$ 的VCdim为 $n + 1$ 。

一个 $n$ 维超平面可以用一个 $n$ 维向量 $w = (w_1, w_2, \dots, w_n)^T$ 和一个实数 $b$ 表示，该平面由 $w \cdot x = b$ 确定。所以对于该超平面分类器对点 $x$ 的分类为 $\text{sgn}(w \cdot x - b)$ ，下面给出上述定理的证明：

*Proof.* 令 $m = n + 1$ ，构造 $S_X = (x_0, x_1, \dots, x_n)$ ，其中 $x_0$ 为原点， $x_i$ 为 $n$ 维one-hot向量，第 $i$ 维为1。则对于任意 $S_Y = (y_0, y_1, \dots, y_n)$ ， $y_i \in \{-1, 1\}$ ，则令 $w = (y_1, y_2, \dots, y_n)$ ， $b = y_0/2$ ，则有：

$$\text{sgn}(w \cdot x_i - b) = \text{sgn}(y_i - y_0/2) = y_i \quad (52)$$

对所有 $0 \leq i \leq n$ 成立，所以证明了存在一个包含 $n + 1$ 个点的sample使得其能被 $H_n$ 打散，接下来证明 $H_n$ 无法打散任意一个大小为 $n + 2$ 的sample。

这需要利用到一个性质，对于任意一个 $S = (x_1, x_2, \dots, x_{n+2})$ ，一定存在其一个划分 $S_1$ 和 $S_2$ ，使得 $S_1$ 的凸壳与 $S_2$ 的凸壳相交。有这条性质的话，我们假设可以找到一个超平面分类器能分类 $S_1$ 和 $S_2$ ，那么该平面肯定分开了该凸壳，得到这两个凸壳不可能相交，于是产生矛盾，就证明了结论。

那么下面来证明上述性质，我们考虑方程组：

$$\sum_{i=1}^{d+2} \alpha_i x_i = 0 \quad \text{and} \quad \sum_{i=1}^{d+2} \alpha_i = 0 \quad (53)$$

该方程组有 $d + 2$ 个未知数 $\alpha_{1\dots d+2}$ ，和 $d + 1$ 个方程，所以肯定有非零解 $\beta_1, \dots, \beta_{d+2}$ ，那么令

$$I_1 = \{i \in [1, d + 2] : \beta_i > 0\} \quad (54)$$

$$I_2 = \{i \in [1, d + 2] : \beta_i < 0\} \quad (55)$$

$$\beta = \sum_{i \in I_1} \beta_i \quad (56)$$

则有：

$$\sum_{i \in I_1} \frac{\beta_i}{\beta} x_i = - \sum_{i \in I_2} \frac{\beta_i}{\beta} x_i \quad (57)$$

由凸壳的定义(书上B.4)可以知道，点 $\sum_{i \in I_1} \frac{\beta_i}{\beta} x_i$ 即在 $I_1$ 下标里的点构成的凸壳里，也在 $I_2$ 下标里的点构成的凸壳里。□

## 2 Boosting

### 2.1 Introduction

这一章节讲述的Boosting是一种将多个弱的分类器合成出一个强的分类器的方法。PAC-learnable的条件对我们来说太过苛刻，我们不妨放低一点标准，所以引入一个新的概念：

**Definition 5** (Weak learning). 如果一个 *Concept Class*  $C$ ，满足存在一个算法 $A$ ，和一个常数 $\gamma > 0$ ，一个固定的多项式 $\text{poly}(\cdot, \cdot, \cdot, \cdot)$ 使得对于任意 $\epsilon > 0$ 和 $\delta > 0$ ，以及任意分布 $D$ ，和任意给定 $c \in C$ ，当 $m \geq \text{poly}(1/\epsilon, 1/\delta, n, \text{size}(c))$ 时：

$$\Pr_{S \sim D^m} \left[ R(h_s) \leq \frac{1}{2} - \gamma \right] \geq 1 - \delta \quad (58)$$

简单来说，存在一个学习concept class  $C$ 的算法 $A$ ，使得当训练数据越来越多的时候，算法 $A$ 返回的分类器错误率小于 $\frac{1}{2}$ 的概率趋近于1。这样的算法被称为weak learning algorithm，其返回的分类器(也就是 $h \in H$ )成为base classifiers。

Boost的中心思想就是运用weak learning algorithm去构造一个strong learner，接下来就来介绍AdaBoost。

#### 2.1.1 AdaBoost

AdaBoost算法如下所示：

---

**Algorithm 1** AdaBoost( $S = ((x_1, y_1), (x_2, y_2), \dots, (x_m, y_m))$ )

---

```

1: for  $i = 1 \rightarrow m$  do
2:    $D_1(i) \leftarrow \frac{1}{m}$ 
3: end for
4: for  $t = 1 \rightarrow T$  do
5:    $h_t \leftarrow$  base classifier in  $H$  with small error  $\epsilon_t = \Pr_{i \sim D_t} [h(x_i) \neq y_i]$ 
6:    $\alpha_t \leftarrow \frac{1}{2} \log \frac{1-\epsilon_t}{\epsilon_t}$ 
7:    $Z_t \leftarrow 2[\epsilon_t(1-\epsilon_t)]^{\frac{1}{2}}$ 
8:   for  $i = 1 \rightarrow m$  do
9:      $D_{t+1}(i) \leftarrow \frac{D_t(i) \exp(-\alpha_t y_i h_t(x_i))}{Z_t}$ 
10:  end for
11: end for
12:  $g \leftarrow \sum_{t=1}^T \alpha_t h_t$ 
13: return  $h = \text{sgn}(g)$ 

```

---

算法简单来看其实就是迭代 $T$ 次，第 $t$ 次迭代找到在分布 $D_t$ 下错误率 $\epsilon_t$ 最小的 $h_t \in H$ ，根据 $\epsilon_t$ 得到 $h_t$ 在 $g$ 中的比例 $\alpha_t$ ，并计算 $D_{t+1}$ 开始下一次迭代。

首先来看 $\alpha_t = \frac{1}{2} \log \frac{1-\epsilon_t}{\epsilon_t}$ ，由于 $h_t \in H$ 是base classifier，所以 $\epsilon_t < \frac{1}{2}$ ，也就有 $\alpha_t > 0$ ，而且错误率 $\epsilon_t$ 越小， $\alpha_t$ 越大，也符合直觉。

再来看分布 $D_t$ 如何计算，一开始 $D_1(i) = \frac{1}{m}$ 为均匀分布。之后更新 $D_t$ 的策略是减少 $h_t(x_i) = y_i$ 的分布，而增加 $h_t(x_i) \neq y_i$ 的分布，也就是多“练习”错误的“题”才有进步的空间。

$Z_t$ 是一个归一化因子，也即：

$$2[\epsilon_t(1-\epsilon_t)]^{\frac{1}{2}} = \sum_{i=1}^m D_t(i) \exp(-\alpha_t y_i h_t(x_i)) \quad (59)$$

接下来说明上式的正确性，由于：

$$\alpha_t = \frac{1}{2} \log \frac{1-\epsilon_t}{\epsilon_t} \quad (60)$$

将该结果代入要证明的结论的右边得到：

$$\begin{aligned}
\text{右边} &= \sum_{i=1}^m D_t(i) \exp(-\alpha_t y_i h_t(x_i)) \\
&= \sum_{i=1}^m D_t(i) \left( \frac{1-\epsilon_t}{\epsilon_t} \right)^{\frac{-1}{2} y_i h_t(x_i)} \\
&= \sum_{y_i \neq h_t(x_i)} D_t(i) \left( \frac{1-\epsilon_t}{\epsilon_t} \right)^{1/2} + \sum_{y_i = h_t(x_i)} D_t(i) \left( \frac{1-\epsilon_t}{\epsilon_t} \right)^{-1/2} \\
&= \epsilon_t \left( \frac{1-\epsilon_t}{\epsilon_t} \right)^{1/2} + (1-\epsilon_t) \left( \frac{1-\epsilon_t}{\epsilon_t} \right)^{-1/2} \\
&= 2(\epsilon_t(1-\epsilon_t))^{1/2} = \text{左边}
\end{aligned} \tag{61}$$

接下来我们给出 $\hat{R}(g)$ 的一个上界：

**Theorem 5.** AdaBoost得到的 $g$ 的empirical error 满足：

$$\hat{R}(g) \leq \exp \left[ -2 \sum_{t=1}^T \left( \frac{1}{2} - \epsilon_t \right)^2 \right] \tag{62}$$

由该定理可以知道， $\epsilon_t$ 越小的话，上界就会越紧，所以我们要选择 $\epsilon_t$ 尽量小的 $h_t$ ，在证明该定理之前，需要一个结论来辅助：

$$D_{t+1}(i) = \frac{e^{-y_i g_t(x_i)}}{m \prod_{s=1}^t Z_s} \tag{63}$$

其中 $g_t = \sum_{s=1}^t g_s \alpha_s$ ，可以用归纳法证明该结论：

1. 基础： $t = 1$ 时， $D_2(i) = \frac{D_1(i) \exp(-\alpha_1 y_i h_1(x_i))}{Z_1} = \frac{\exp(-y_i g_1(x_i))}{m Z_1}$ 。
2. 归纳：假设结论对 $1, 2, \dots, t-1$ 成立，由算法的定义有：

$$D_{t+1}(i) = \frac{D_t(i) \exp(-\alpha_t y_i h_t(x_i))}{Z_t} \tag{64}$$

由归纳假设可以知道：

$$D_t(i) = \frac{\exp(-y_i g_{t-1}(x_i))}{m \prod_{s=1}^{t-1} Z_s} \tag{65}$$

代入上式可以得到：

$$\begin{aligned}
D_{t+1}(i) &= \frac{\exp(-(\alpha_t y_i h_t(x_i) + y_i g_{t-1}(x_i)))}{m \prod_{s=1}^t Z_s} \\
&= \frac{\exp(-y_i g_t(x_i))}{m \prod_{s=1}^t Z_s}
\end{aligned} \tag{66}$$

所以归纳成立。

有了这个结论，现在证明上述定理：

*Proof.* 由empirical error 的定义可以知道， $\hat{R}(g) = \frac{1}{m} \sum_{i=1}^m 1_{g(x_i) \neq y_i}$ ，所以有：

$$\begin{aligned} \hat{R}(g) &= \frac{1}{m} \sum_{i=1}^m 1_{g(x_i) \neq y_i} \\ &\leq \frac{1}{m} \sum_{i=1}^m e^{-g(x_i)y_i} \end{aligned} \quad (67)$$

由于  $\sum_{i=1}^m D_{T+1}(i) = 1 = \sum_{i=1}^m \frac{\exp(-y_i g_T(x_i))}{m \prod_{s=1}^T Z_s}$ ，所以有：

$$\sum_{i=1}^m \frac{1}{m} \exp(-y_i g_T(x_i)) = \prod_{s=1}^T Z_s = \prod_{s=1}^T 2[\epsilon_s(1 - \epsilon_s)]^{\frac{1}{2}} \quad (68)$$

代入上式可以得到：

$$\begin{aligned} \hat{R}(g) &\leq \frac{1}{m} \sum_{i=1}^m e^{-g(x_i)y_i} \\ &\leq \prod_{s=1}^T 2[\epsilon_s(1 - \epsilon_s)]^{\frac{1}{2}} \\ &= \prod_{s=1}^T 2\sqrt{-\left(\epsilon_s - \frac{1}{2}\right)^2 + \frac{1}{4}} \\ &= \prod_{s=1}^T \sqrt{1 - 4\left(\epsilon_s - \frac{1}{2}\right)^2} \\ &\leq \prod_{s=1}^T e^{-2\left(\epsilon_s - \frac{1}{2}\right)^2} \\ &= \exp\left[\sum_{s=1}^T -2\left(\epsilon_s - \frac{1}{2}\right)^2\right] \end{aligned} \quad (69)$$

□

所以从这个结论我们可以看到，随着迭代次数 $T$ 的增加， $\hat{R}(g)$ 会越来越小，但不意味着 $R(g)$ 就会越来越小，也即我们不仅要考虑 $\hat{R}(g)$ 还需要考虑它和 $R(g)$ 的差距，我们先得到 $g$ 的假设空间 $\mathcal{F}_T$ ：

$$\mathcal{F}_T = \left\{ \text{sgn} \left( \sum_{t=1}^T \alpha_t h_t \right) : \alpha_t \in \mathbb{R}, h_t \in H, t \in [1, T] \right\} \quad (70)$$

由书上结论，可以知道

$$VCdim(\mathcal{F}_T) \leq 2(d+1)(T+1)\log_2((T+1)e) \quad (71)$$

其中 $d = VCdim(H)$ 。从这个式子可以看出， $VCdim(\mathcal{F}_T)$ 按 $O(T \log T)$ 增长，由前面 $VCdim$ 的性质可以知道， $\hat{R}(g)$ 和 $R(g)$ 的差距在不断增大，也就是说随着迭代次数的增多，可能导致Overfit。

## 3 On-Line Learning

### 3.1 Introduction

On-Line Learning指的是训练样例不是一下子全部给出，而是分成 $T$ 轮，每一轮给出一个数据 $(x_t, y_t)$ ，我们需要利用这个数据修正我们的模型，这时候我们就不能假设训练数据满足某种分布，而且我们还希望学会某种concept之前犯尽量少的错误。接下来就介绍几种在线学习的思路，以及评价标准。

### 3.2 Prediction with expert advice

这是一类在线学习的思路，先给 $N$ 个expert，其实也就是一个大小为假设空间 $H$ ，每遇到一个数据 $x_t$ ，会综合 $H$ 中expert给出预测 $\hat{y}_t$ ，然后得到label  $y_t$ ，根据预测是否正确来调整expert的“发言权”，最后得到一个模型。

引入一个衡量标准regret(我们希望最小化regret)，它的定义式为：

$$R_T = \sum_{t=1}^T L(\hat{y}_t, y_t) - \min_{i=1}^N \sum_{t=1}^T L(y_{t,i}, y_t) \quad (72)$$

$L(\hat{y}_t, y_t)$ 是Loss-function， $R_T$ 表示 $T$ 轮下来总的Loss，和犯错误最少的那个expert的Loss的差。这就是为什么叫做regret，如果当时听了那个最聪明的expert，就不会多犯这么多错误了。

#### 3.2.1 Mistake bounds and Halving algorithm

在这里我们仅考虑realizable-case，也就是 $c \in H$ 。Halving algorithm 就是一个非常简单的想法，遇到一个 $x_t$ ，让 $H$ 中的所有expert都做出预测，然后和人数多的（一定过半）一方做一样的预测 $\hat{y}_t$ ，如果错了，就把这一堆expert全部从 $H$ 中踢出，这样既保证了正确性也让 $H$ 减少了至少一半。



这里引入另外一个衡量标准mistake bound model，它衡量的是一个在线学习算法 $A$ 的能力，首先固定concept  $c$ ，令：

$$M_A(c) = \max_{x_1, x_2, \dots, x_T} |mistakes(A, c)| \quad (73)$$

下标 $x_1, x_2, \dots, x_T$ 表示任取一个正整数 $T$ ，且 $T$ 轮给出的 $x_t$ 也是任取，综合起来就是任取一个在线序列。

然后再扩展到concept class  $C$ ：

$$M_A(C) = \max_{c \in C} M_A(c) \quad (74)$$

接下来我们给出Halving algorithm的mistake bound：

**Theorem 6.** 对于有限大小的假设空间 $H$ ，考虑realizable-case时有：

$$M_{Halving}(H) \leq \log_2 |H| \quad (75)$$

*Proof.* 根据Halving algorithm算法的性质，每一次犯错，会导致 $H$ 减少一半，所以犯错达到 $\log_2 |H|$ 之后， $H$ 中就只剩下一个expert了，由于是realizable-case，所以剩下的这一个expert就是 $c$ ，而 $c$ 是不会犯错的。  $\square$

如此我们就找到了其上界，我们还可以找到其下界：

**Theorem 7.** 对于有限大小的假设空间 $H$ ，考虑realizable-case时有：

$$VCdim(H) \leq M_{Halving}(H) \leq \log_2 |H| \quad (76)$$

*Proof.* 令 $d = VCdim(H)$ ，也即存在 $S = (x_1, x_2, \dots, x_d)$ 满足 $|H_S| = 2^d$ ，我们就按照对手策略构造 $y_1, y_2, \dots, y_d$ ，也即第 $t$  ( $1 \leq t \leq d$ )轮，如果 $\hat{y}_t = 1$ ，就让 $y_t = -1$ ，可以知道在这 $d$ 轮，算法永远都在犯错而且 $H$ 不会为空，所以找到一组 $S$ ，使得其犯错至少为 $d$ 次，证明了结论。  $\square$

### 3.2.2 Weighted majority algorithm

Halving algorithm之所以敢把犯错的都去掉，就是因为其考虑的是realizable-case，但是现实中，这个假设很难实现，我们不能保证 $H$ 中一定有一个永远不会错的expert，只能够让算法最后能达到准确率 $p$  ( $p \leq 1$ )，这时候去掉犯错的expert就不妥了，可能到最后 $H$ 就被删光了。一个较为缓和的方法，就是根据一个expert的犯错次数的多少来决定它的决定在最终决定中的比重。

这就是Weighted majority algorithm，它赋予每个 $H$ 中 $h_i$ 一个权重 $w_{t,i}$ ，该权重会随着算法的进行更新，所以与 $t$ 有关，算法流程大致如下：

1. 初始化  $w_{1,i} = 1$ , 对于  $1 \leq i \leq N$ 。
2. 第  $t$  轮得到  $x_t$ , 如果  $\sum_{h_i(x_t)=1} w_{t,i} > \sum_{h_i(x_t)=-1} w_{t,i}$ , 那么  $\hat{y}_t = 1$ , 否则  $\hat{y}_t = -1$ 。
3. 更新  $w_{t+1,i}$ :

$$w_{t+1,i} = \begin{cases} w_{t,i} & h_i(x_t) = y_t \\ \beta w_{t,i} & h_i(x_t) \neq y_t \end{cases} \quad (77)$$

4. 令  $t+ = 1$ , goto 步骤2, 直到  $t > T$ 。

由于现在是 non-realizable-case, 像之前算法那样用  $M_A(C)$  来评估其性能就不妥, 因为极端错误可能会随着  $T$  的增加而增加, 于是我们固定轮数  $T$ , 再来比较, 也用  $m_T$  表示  $T$  轮数据下来, 算法一共出错次数, 用  $m_T^*$  表示  $T$  轮数据下来, 出错最少的 expert 的出错次数, 那么可以提供  $m_T$  的上界:

**Theorem 8.** 假如  $\beta \in (0, 1)$ , 且  $|H| = N$ , 假设  $T$  轮的数据固定,  $m_T$  表示这  $T$  轮算法出错个数,  $m_T^*$  表示这  $T$  轮中犯错最少的 expert 的出错次数, 则有:

$$m_T \leq \frac{\log N + m_T^* \log \frac{1}{\beta}}{\log \frac{2}{1+\beta}} \quad (78)$$

*Proof.* 用势能分析可以简单地证明这个结论, 定义势能函数  $W_t = \sum_{i=1}^N w_{t,i}$ , 它满足如下性质:

1.  $W_t$  随着  $t$  的增大单调不上升。
2.  $W_t \geq w_{t,i} \geq 0$  对于  $1 \leq i \leq N$  都成立。

考虑第  $t$  轮算法做了错误的预测, 那么一定有做出错误决定的一方的权值和大于  $1/2 W_t$ , 根据算法描述, 这些 expert 都会受到  $\beta$  的惩罚, 所以一定有:

$$W_{t+1} \leq \frac{1}{2} \beta W_t + \frac{1}{2} W_t = \frac{1+\beta}{2} W_t \quad (79)$$

其中  $\frac{1+\beta}{2} < 1$ , 所以有:

$$W_T \leq \left( \frac{1+\beta}{2} \right)^{m_T} N \quad (80)$$

假设在这  $T$  轮中最厉害的 expert 为  $h_i$ , 有性质2可以知道:

$$W_T \geq w_{T,i} = \beta^{m_T^*} \quad (81)$$

联立如上两式子，可以得到：

$$\beta^{m_T^*} \leq \left(\frac{1+\beta}{2}\right)^{m_T} N \quad (82)$$

$$m_T^* \log(\beta) \leq m_T \log\left(\frac{1+\beta}{2}\right) + \log N \quad (83)$$

$$-m_T^* \log(\beta) \geq -m_T \log\left(\frac{1+\beta}{2}\right) - \log N \quad (84)$$

$$\frac{m_T^* \log\left(\frac{1}{\beta}\right) + \log N}{\log\left(\frac{2}{1+\beta}\right)} \geq m_T \quad (85)$$

$$(86)$$

□

这就证明了结论。

### 3.2.3 Randomized weighted majority algorithm

我们还可以将上述算法改成一个随机算法，只需要把 $w_{t,i}$ 变成概率就行：

1. 初始化 $w_{1,i} = 1$ ,  $p_{1,i} = 1/N$ , 对于 $1 \leq i \leq N$ 。
2. 第 $t$ 轮得到 $x_t$ , 算法按照 $p_{t,i}$ 的概率决定选择 $h_i$ 的决定。
3. 更新 $p_{t+1,i}$ ,  $w_{t+1,i} = 1$ :

$$w_{t+1,i} = \begin{cases} w_{t,i} & h_i(x_t) = y_t \\ \beta w_{t,i} & h_i(x_t) \neq y_t \end{cases} \quad (87)$$

$$p_{t+1,i} = w_{t+1,i} / \sum_{i=1}^N w_{t+1,i} \text{ (归一化)} \quad (88)$$

4. 令 $t+ = 1$ , goto 步骤2, 直到 $t > T$ 。

为什么要使用随机算法，这是因为任意一个**确定性算法** $A$ 都无法做到让 $R_T = o(N)(O(N)$ 但不是 $\Theta(n)$ )，因为可能会碰到很极端的 $x_t$ 和 $N$ ，比方说 $N = 2$ ，而两个expert 一个只返回1，另一个只返回-1。而且每一轮， $y_t$ 都和 $\hat{y}_t$ 相反（这是可行的，因为算法是确定的），那么 $m_T = T$ ,  $m_T^* \leq T/2$ ，所以：

$$R_T = m_T - m_T^* \geq T/2 = \Omega(N) \quad (89)$$

对于随机算法，我们需要修改 $R_T$ 的定义，这是因为对于给定的 $x_t$ ，算法返回的结果并不确定，可以用其期望来代替：

$$R_T = \mathcal{L}_T - \mathcal{L}_T^{\min} \quad (90)$$

其中 $\mathcal{L}_T = \sum_{t=1}^T E[l(y_t, \hat{y}_t)] = \sum_{t=1}^T \sum_{i=1}^N p_{t,i} l_{t,i}$ ，表示 $T$ 轮下来的期望错误。

$\mathcal{L}_T^{\min} = \min_{i=1}^N \sum_{t=1}^T l_{t,i}$ 。表示犯错误最少的expert的犯错误数，这一个量是不涉及随机变量的。

这时候我们可以给出 $\mathcal{L}_T$ 和 $\mathcal{L}_T^{\min}$ 差距的一个bound，进而给出 $R_T$ 的bound：

**Theorem 9.** 假定 $\beta \in [1/2, 1)$ ，那么对于 $T > 1$ ，有如下不等式成立：

$$\mathcal{L}_T \leq \frac{\log N}{1 - \beta} + (2 - \beta) \mathcal{L}_T^{\min} \quad (91)$$

实际中，令 $\beta = \max \left\{ 1/2, 1 - \sqrt{(\log N)/T} \right\}$ ，那么有如下bound成立：

$$\mathcal{L}_T \leq \mathcal{L}_T^{\min} + 2\sqrt{T \log N} \quad (92)$$

*Proof.* 令 $L_t = \sum_{i=1}^N p_{t,i} l_{t,i}$ ， $W_t = \sum_{i=1}^N w_{t,i}$ ，所以有 $p_{t,i} = w_{t,i}/W_t$ 。类似Weighted majority algorithm，我们采用势能分析的方法，将 $W_t$ 作为势能函数。

$$\begin{aligned} W_{t+1} &= \sum_{l_{t,i}=1} \beta w_{t,i} + \sum_{l_{t,i}=0} w_{t,i} \\ &= \sum_{i=1}^N w_{t,i} + \sum_{l_{t,i}=1} (\beta - 1) w_{t,i} \\ &= W_t + W_t \sum_{l_{t,i}=1} (\beta - 1) p_{t,i} \\ &= W_t + W_t (\beta - 1) L_t \\ &= W_t (1 + (\beta - 1) L_t) \end{aligned} \quad (93)$$

所以可以得到： $W_{T+1} = N \prod_{t=1}^T (1 + (\beta - 1) L_t)$ ，又因为 $W_{T+1} \geq w_{T+1,i}$ ，所以 $W_{T+1} \geq \beta \mathcal{L}_T^{\min}$ ，联立可以得到：

$$N \prod_{t=1}^T (1 + (\beta - 1) L_t) \geq \beta \mathcal{L}_T^{\min} \quad (94)$$

两边取Log得到:

$$\log N + \sum_{t=1}^T \log(1 - (1 - \beta)L_t) \geq \mathcal{L}_T^{\min} \log \beta \quad (95)$$

当 $0 < x < 1$ 时,  $\log(1 - x) \leq -x$ , 所以可以放缩上式:

$$\begin{aligned} \mathcal{L}_T^{\min} \log \beta &\leq \log N - \sum_{t=1}^T \log(1 - (1 - \beta)L_t) \\ &\leq \log N - \sum_{t=1}^T (1 - \beta)L_t \\ &= \log N - (1 - \beta)\mathcal{L}_T \end{aligned} \quad (96)$$

两边同时乘以-1, 并带进log内部可以得到:

$$(1 - \beta)\mathcal{L}_T \leq \mathcal{L}_T^{\min} \log \frac{1}{\beta} + \log N \quad (97)$$

$$\begin{aligned} \mathcal{L}_T &\leq -\frac{\mathcal{L}_T^{\min} \log \beta}{(1 - \beta)} + \frac{\log N}{(1 - \beta)} \\ &\leq -\frac{\log(1 - (1 - \beta))}{(1 - \beta)} \mathcal{L}_T^{\min} + \frac{\log N}{(1 - \beta)} \end{aligned} \quad (98)$$

由于 $-\log(1 - x) \leq x + x^2$ , 所以:

$$\mathcal{L}_T \leq (2 - \beta)\mathcal{L}_T^{\min} + \frac{\log N}{(1 - \beta)} \quad (99)$$

到此为止证明了第一部分, 让右边的式子对 $\beta$ 求导并令其为0, 就可以找到一个最紧的bound, 此时 $\beta_0 = 1 - \sqrt{(\log N)/T}$ , 如果 $\beta_0 > 1/2$  (定理的前提), 则最优解在 $\beta_0$ 取到, 否则在边界1/2取到。这就证明了定理的第二部分, 并做适当变形可以得到:

$$\mathcal{R}_T \leq 2\sqrt{T \log N} \quad (100)$$

□

这个定理说明了, 如上随机算法RWM的期望regret的上界为 $\mathcal{R}_T \leq 2\sqrt{T \log N}$ , 接下来的定理说明如果仅用期望regret作为指标的话, RWM 已经达到了极限:

**Theorem 10.** 当 $N = 2$ , 存在一个loss的随机loss vector序列, 使得对于任意在线学习算法都有:  $E[R_T] \geq \sqrt{T/8}$ 。

*Proof.* 令 $l_t$ 等概率从 $(0, 1)^T$ 和 $(1, 0)^T$ 中取得，不论是随机算法还是确定算法，都可以用 $p_{t,i}$ 的形式来描述：

$$\begin{aligned} E[R_t] &= E[\mathcal{L}_T] - E[\mathcal{L}_T^{min}] \\ &= \sum_{t=1}^T E[p_{t,1}l_{t,1} + p_{t,2}l_{t,2}] - E[\mathcal{L}_T^{min}] \\ &= T/2 - E[\mathcal{L}_T^{min}] \end{aligned} \quad (101)$$

又因为：

$$\begin{aligned} \mathcal{L}_T^{min} &= \min\{\mathcal{L}_{T,1}, \mathcal{L}_{T,2}\} \\ &= \frac{1}{2}(\mathcal{L}_{T,1} + \mathcal{L}_{T,2} - |\mathcal{L}_{T,1} - \mathcal{L}_{T,2}|) \\ &= T/2 - |L_{T,1} - T/2| \end{aligned} \quad (102)$$

所以：

$$\begin{aligned} E[R_t] &= E[|L_{T,1} - T/2|] \\ &= E\left[\left|\sum_{t=1}^T \frac{1 + \sigma_t}{2} - T/2\right|\right] \\ &= E\left[\left|\sum_{t=1}^T \frac{\sigma_t}{2}\right|\right] \end{aligned} \quad (103)$$

使用书上的定理D.4，并且令 $x_t = 1/2$ 得到：

$$E[R_t] = E\left[\left|\sum_{t=1}^T \sigma_t x_t\right|\right] \geq \sqrt{\frac{1}{2} \sum_{t=1}^T x_t^2} = \sqrt{T/8} \quad (104)$$

□

如何使用这个定理去证明 $R_t = \Omega(\sqrt{T \log N})$ ，没有想出来！！。

## 4 Dimensionality Reduction

### 4.1 Principal Component Analysis

我们经常用一个 $n$ 维的向量来描述一个事物，比如说一个单词，一张图片。那么有时候 $n$ 太大导致处理太困难。希望能将数据重新表示成一个 $k$ 维（ $k$  远远小于 $n$ ）的向量。比如有100个2维向量，恰好都落在一条直线上，那么只需要一个Pd，加

上100个实数就可以表示，但是一般情况下数据不可能恰好落在一条直线上。那么想把这100个点从二维降到一维，就必须要有损失。那么一个直观的做法就是，找到一条直线，使得这100个点离这条直线的偏离最小，然后对于某个点，它的降维后的结果就是在这个直线上的投影。

#### 4.1.1 奇异值分解(Singular Value Decomposition)

首先需要约定一下奇异值分解SVD的形式（与线性代数(下)有点不同），对于一个 $n$ 行 $m$ 列的矩阵 $A$ ，设其SVD分解为：

$$A = U\Sigma V^T \quad (105)$$

其中 $U = (u_1, u_2, \dots, u_r)$ 是一个 $n$ 行 $r$ 列的矩阵， $r$ 为 $A$ 的秩(rank)， $\Sigma$ 为 $r$ 行 $r$ 列的对角方阵。 $V$ 为 $m$ 行 $r$ 列的矩阵。

满足 $U$ 中 $r$ 个列向量两两正交，也即有 $U^T U = I_r$ ，类似地有 $V^T V = I_r$ 。

#### 4.1.2 正交投影矩阵(orthogonal projection matrix):

给定 $k$ 个相互正交的 $n$ 维向量 $(a_1, a_2, \dots, a_k)$ 构成一组基 $A$ ，则对于给定任意 $n$ 维向量 $b$ ，分别求解 $b$ 在 $a_i$ 上的投影长度 $x_i$ ，再合成得到其投影向量 $p = \sum_{i=1}^k a_i x_i$ 。由于 $x_i = \frac{a_i^T b}{a_i^T a_i}$ ，故可以得到：

$$p = \left( \sum_{i=1}^k \frac{a_i a_i^T}{a_i^T a_i} \right) b \quad (106)$$

令 $P = \sum_{i=1}^k \frac{a_i a_i^T}{a_i^T a_i}$ ， $U_k = \left( \frac{a_1}{\sqrt{a_1^T a_1}}, \dots, \frac{a_k}{\sqrt{a_k^T a_k}} \right)$ ，则有：

$$P = U_k U_k^T \quad (107)$$

$P$ 就是正交投影矩阵，正交表示其对应的基 $A$ 是正交的，投影矩阵的意思就是用 $P$ 左乘某个向量 $b$ 就可以得到其在 $A$ 上的投影 $p$ 。那么一个正交投影矩阵满足以下性质：

1.  $P^T = P$ ：由公式(2)可以得到。
2.  $P^2 = P$ ：一个向量投影到 $A$ 上之后，再投影还是这个向量。

#### 4.1.3 PCA

假定输入数据为 $X = (x_1, x_2, \dots, x_m)$ ， $X$ 是一个 $n \times m$ 的矩阵，我们希望将其降至 $k$ 维，并且使得受到的损失最小，也即找到一个正交投影矩阵 $P^*$ （ $P^*$ 对应 $k$ 个 $n$

维正交基），满足：

$$P^* = \arg \min_P \|PX - X\|_F \quad (108)$$

也就是投影后，两个矩阵的差距最小，由于：

$$\begin{aligned} \|PX - X\|_F^2 &= \text{Tr}((PX - X)^T(PX - X)) \\ &= \text{Tr}(X^T P^T PX - X^T PX - X^T P^T X - X^T X) \\ &= \text{Tr}(-X^T PX - X^T X) \\ &= \text{Tr}(-X^T PX) - \text{Tr}(X^T X) \end{aligned} \quad (109)$$

上述推导用到了  $P^T = P$ ， $P^2 = P$ ，和矩阵迹 $\text{Tr}$ 算符的线性性质。由于 $X$ 是给定的，所以：（假设 $P = U_k U_k^T$ ， $U_k$ 为 $n \times k$ 矩阵，且列向量互相正交）。

$$\begin{aligned} P^* &= \arg \min_P \|PX - X\|_F \\ &= \arg \max_P \text{Tr}(X^T PX) \\ &= \arg \max_{U_k} \text{Tr}((X^T U_k)((X^T U_k)^T)) \\ &= \arg \max_{U_k} \text{Tr}(U_k^T (X X^T) U_k) \\ &= \arg \max_{U_k} \sum_{i=1}^k u_i^T (X X^T) u_i \end{aligned} \quad (110)$$

令 $C = X X^T$ ，取 $u_i$ 为将 $C$ 奇异值分解后，第 $i$ 个左奇异值向量(left singular vector)。则可以得到最优解 $U_k$ ，所以 $PX = U_k U_k^T X$ ，令 $Y = U_k^T X$ ，就得到降维后的向量。（后面可以看到，其实左右奇异值向量是一样）

下面解释原理，假设 $X$ 的奇异值分解为：

$$X = U \Sigma V^T \quad (111)$$

那么有：

$$\begin{aligned} X X^T &= U \Sigma V^T V \Sigma^T U^T \\ &= U \Sigma \Sigma^T U^T \\ &= \sum_{i=1}^r \sigma_i^2 u_i u_i^T \end{aligned} \quad (112)$$

所以有 $u_1 X X^T u_1^T = \sigma_1^2$ 最大， $u_2 X X^T u_2^T = \sigma_2^2$ 次大.....



## 4.2 Kernel Principal Component Analysis

有时候在 $n$ 维下，线性分类无法区分一类概念，但是将其映射到更高的维度就可以了。本来我们是直接把数据从 $n$ 维降到 $k$ 维，现在我们是将数据先映射到一个更高的维度的Hilbert space（定义了内积的空间），然后再降到 $k$ 维。我们设这样的映射为 $\Phi(x)$ ，令映射后的数据为 $X = (\Phi(x_1), \Phi(x_2), \dots, \Phi(x_m))$ ，然后对 $X'$ 套用PCA即可。

不过我们有时候并不需要知道映射 $\Phi(x)$ 是什么，我们只需要知道一个Kernel Matrix  $K$ ，它表示两两元素的在高维空间的内积。假设我们已经把数据映射后得到了 $X$ ，注意这时候 $X$ 就不是 $n$ 行， $m$ 列了（因为维度更高）。那么我们可以定义 $K = X^T X$ （注意这里的矩阵乘法，内积由其所在的高维空间定义，但是由于内积的性质，我们依然可以套用原来的写法）。

直接对 $X$ 进行PCA，也就是对 $XX^T$ 进行SVD，我们假设 $X$ 的SVD为 $X = U\Sigma V^T$ ，那么有 $XX^T = U\Sigma^2 U^T$ ， $K = V\Sigma^2 V^T$ 。令 $\Lambda = \Sigma^2$ ， $\lambda_i$ 表示第 $i$ 个对角元素。

我们的目标是，将降维结果 $Y$ 能用 $K$ 表示，而不是 $X$ 的形式。由之前的结论：

$$Y = U_k^T X \quad (113)$$

那么我们先从 $U_k$ 试着用 $K$ 来表示，我们把 $X = U\Sigma V^T$ 两边同时右乘 $V\Sigma^{-1}$ 得到 $U = XV\Sigma^{-1}$ （ $\Sigma$ 是可逆的），改写一下：

$$\begin{aligned} U &= XV\Lambda^{-1/2} \\ &= X\left(\frac{v_1}{\sqrt{\lambda_1}}, \frac{v_2}{\sqrt{\lambda_2}}, \dots, \frac{v_r}{\sqrt{\lambda_r}}\right) \end{aligned} \quad (114)$$

所以有：

$$U_k = \left(X \frac{v_1}{\sqrt{\lambda_1}}, X \frac{v_2}{\sqrt{\lambda_2}}, \dots, X \frac{v_k}{\sqrt{\lambda_k}}\right) \quad (115)$$

带入得到：

$$\begin{aligned} Y &= U_k^T X \\ &= \left(X \frac{v_1}{\sqrt{\lambda_1}}, X \frac{v_2}{\sqrt{\lambda_2}}, \dots, X \frac{v_k}{\sqrt{\lambda_k}}\right)^T X \\ &= \left(X^T X \frac{v_1}{\sqrt{\lambda_1}}, X^T X \frac{v_2}{\sqrt{\lambda_2}}, \dots, X^T X \frac{v_k}{\sqrt{\lambda_k}}\right)^T \\ &= \left(K \frac{v_1}{\sqrt{\lambda_1}}, K \frac{v_2}{\sqrt{\lambda_2}}, \dots, K \frac{v_k}{\sqrt{\lambda_k}}\right)^T \end{aligned} \quad (116)$$

由特征向量性质 $Kv_i = \lambda_i v_i$ ，代入得到：

$$Y = (\sqrt{\lambda_1}v_1, \sqrt{\lambda_2}v_2, \dots, \sqrt{\lambda_k}v_k)^T \quad (117)$$

也就是给定核矩阵 $K$ ，就能够求出原 $m$ 个数据的降维表示。

### 4.3 Johnson-Lindenstrauss lemma

该引理说的是，对于 $m$ 个 $n$ 维的点，可以用一个映射将其降维至 $k$  ( $k \geq O(\frac{\log m}{\epsilon^2})$ )，同时满足任意两点之间的距离比原来不超过 $(1 \pm \epsilon)$  倍。下面开始证明：

**Lemma 11.** 假定 $Q$ 服从自由度为 $k$ 的卡方分布，则对于任意 $0 < \epsilon < 1/2$ ，有如下不等式成立：

$$\Pr[(1 - \epsilon)k \leq Q \leq (1 + \epsilon)k] \geq 1 - 2e^{-(\epsilon^2 - \epsilon^3)k/4} \quad (118)$$

*Proof.* 正难则反，先计算 $Q$ 在取值范围外的概率，再减去。

$$\begin{aligned} \Pr[Q \geq (1 + \epsilon)k] &= \Pr[\exp(\lambda Q) \geq \exp(\lambda(1 + \epsilon)k)] \\ &\leq \frac{E[\exp(\lambda Q)]}{\exp(\lambda(1 + \epsilon)k)} \end{aligned} \quad (119)$$

$$E[\exp(\lambda Q)] = \prod_{i=1}^k E[e^{\lambda X_i^2}] \quad (120)$$

$$\begin{aligned} E[e^{\lambda X_i^2}] &= \int_{-\infty}^{\infty} \frac{e^{\lambda t^2}}{\sqrt{2\pi}} e^{-t^2/2} dt \\ &= \frac{1}{\sqrt{1 - 2\lambda}} \end{aligned} \quad (121)$$

式(17)要求 $Re(\lambda) < 1/2$ 。所以(15)可以继续写成：

$$\Pr[Q \geq (1 + \epsilon)k] \leq \frac{(1 - 2\lambda)^{-k/2}}{\exp(\lambda(1 + \epsilon)k)} \quad (122)$$

将等式右边对 $\lambda$  求导，并令导数等于0，得到：

$$\lambda^* = \frac{\epsilon}{2(\epsilon + 1)} < 1/2 \quad (123)$$

带入 $\lambda^*$ 得到：

$$\Pr[Q \geq (1 + \epsilon)k] \leq \left(\frac{1 + \epsilon}{\exp(\epsilon)}\right)^{k/2} \quad (124)$$

考虑到

$$\begin{aligned} \exp(\epsilon - (\epsilon^2 - \epsilon^3)/2) &\geq 1 + [\epsilon - (\epsilon^2 - \epsilon^3)/2] + [\epsilon - (\epsilon^2 - \epsilon^3)/2]^2/2 \\ &= (1 + \epsilon + (5\epsilon^4)/8 - \epsilon^5/4 + \epsilon^6/8) \\ &\geq 1 + \epsilon \end{aligned} \quad (125)$$

故有：

$$\Pr[Q \geq (1 + \epsilon)k] \leq \exp(-k(\epsilon^2 - \epsilon^3)/4) \quad (126)$$

类似可以证明:

$$\Pr[Q \leq (1 - \epsilon)k] \leq \exp(-k(\epsilon^2 - \epsilon^3)/4) \quad (127)$$

由Union bound可以得到引理成立。  $\square$

**Lemma 12.** 给定 $n$ 维向量 $x$ , 和一个 $k$ 行 $n$ 列的矩阵 $A$ , 保证 $A$ 中的元素均独立同 $N(0, 1)$ 分布, 那么对于任意 $0 < \epsilon < 1/2$ 有:

$$\Pr[(1 - \epsilon) \|x\|^2 \leq \left\| \frac{1}{\sqrt{k}} Ax \right\|^2 \leq (1 + \epsilon) \|x\|^2] \geq 1 - 2e^{-(\epsilon^2 - \epsilon^3)k/4} \quad (128)$$

*Proof.*

上式左边

$$= \Pr[(1 - \epsilon)k \leq \|Ax\|^2 / \|x\|^2 \leq (1 + \epsilon)k] \quad (129)$$

令 $\hat{x} = Ax$ ,  $T_j = \hat{x}_j / \|x\|$ , 有 $T_j$ 服从 $N(0, 1)$ , 故得到 $Q = \sum_{i=1}^k T_j^2$ 服从自由度为 $k$ 的卡方分布。由Lemma11 可以得到结论成立。  $\square$

**Lemma 13** (Johnson-Lindenstrauss). 对于任意 $0 < \epsilon < 1/2$ , 和任意整数 $m > 4$ , 令 $k = \frac{20 \log m}{\epsilon^2}$ 。则对于任意 $n$ 为空间的 $m$ 个点构成的集合 $V$ , 存在一个映射 $f: R^n \rightarrow R^k$ , 使得对于任意 $u, v \in V$ ,

$$(1 - \epsilon) \|u - v\|^2 \leq \|f(u) - f(v)\|^2 \leq (1 + \epsilon) \|u - v\|^2 \quad (130)$$

*Proof.* 我们将 $V$ 中的点, 标号为 $v_1, v_2, \dots, v_m$ , 令事件 $A_{ij}$ 表示 $x = v_i - v_j$ 满足Lemma12的不等式。则只要能说明:

$$\Pr\left[\bigcap_{1 \leq i < j \leq m} A_{ij}\right] > c \quad (131)$$

其中 $c$ 为一给定大于0的常数。由Lemma2可知,

$$\Pr[A_{ij}^C] = 1 - \Pr[A_{ij}] \leq 2e^{-(\epsilon^2 - \epsilon^3)k/4} \quad (132)$$

所以可以得到:

$$\begin{aligned} \Pr\left[\bigcap_{1 \leq i < j \leq m} A_{ij}\right] &= 1 - \Pr\left[\bigcup_{1 \leq i < j \leq m} A_{ij}^C\right] \\ &\geq 1 - \sum_{1 \leq i < j \leq m} \Pr[A_{ij}^C] \\ &\geq 1 - (m - 1)m/2 * 2e^{-(\epsilon^2 - \epsilon^3)k/4} \end{aligned} \quad (133)$$

取 $\epsilon = 1/2$ 上式概率取到最小，当 $k = \frac{20 \log m}{\epsilon^2}$ 时，有：

$$\begin{aligned}
 \Pr\left[\bigcap_{1 \leq i < j \leq m} A_{ij}\right] &\geq 1 - (m-1)m/2 * 2m^{-(5-2.5)} \\
 &\geq 1 - m^2 * 2m^{-2.5} \\
 &\geq 1 - 2m^{-0.5} \\
 &> 0
 \end{aligned} \tag{134}$$

□