

ML note

mstyoda 骆轩源

Contents

1	Rademacher Complexity and VC-Dimension	2
1.1	Rademacher complexity	2
1.2	Growth function	5
1.3	VC-dimension	8
2	Boosting	12
2.1	Introduction	12
2.1.1	AdaBoost	12
3	Dimensionality Reduction	16
3.1	Principal Component Analysis	16
3.1.1	奇异值分解(Singular Value Decomposition	16
3.1.2	正交投影矩阵(orthogonal projection matrix):	16
3.1.3	PCA	17
3.2	Kernel Principal Component Analysis	18
3.3	Johnson-Lindenstrauss lemma	19

1 Rademacher Complexity and VC-Dimension

1.1 Rademacher complexity

Rademacher Complexity是用来衡量一个函数族 $G : X \rightarrow \mathbb{R}$ 的复杂程度的指标，它考验的是 G 对于随机噪声的拟合能力。比如给定样本 $S = (z_1, z_2 \dots z_m)$ ，其中 $z_i = (x_i, y_i)$ ，那么先随机生成一个序列 $\sigma = (\sigma_1, \sigma_2 \dots \sigma_m)$ ，然后在 G 中找到一个函数 g ，使得 $\mathbf{g}(S) \cdot \sigma$ 最大，把这个值对于 σ 求期望，就得到了Empirical Rademacher complexity。

Definition 1. 给定函数族 G ，其中的函数将 Z 映射到实数区间 $[a, b]$ ，并且给定一个大小为 m 的 S ， σ_i 独立均匀分布在 $\{-1, 1\}$ 内，则定义 G 对于 S 的*Empirical Rademacher complexity*为：

$$\hat{\mathcal{R}}_S(G) = E_{\sigma} \left[\sup_{g \in G} \frac{1}{m} \sum_{i=1}^m \sigma_i g(z_i) \right] \quad (1)$$

很自然地，如果我们不固定 S ，只固定 m ，让 $z_1, z_2 \dots z_m$ 独立同分布于 D ，则可以定义 G 对于样本大小为 m 的Rademacher complexity为：

Definition 2. 给定函数族 G ，其中的函数将 Z 映射到实数区间 $[a, b]$ ，并且给定 m ， z_i 独立同分布 D ， σ_i 独立均匀分布在 $\{-1, 1\}$ 内，则定义 G 对于 S 的*Rademacher complexity*为：

$$\begin{aligned} \mathcal{R}_m(G) &= E_{S, \sigma} \left[\sup_{g \in G} \frac{1}{m} \sum_{i=1}^m \sigma_i g(z_i) \right] \\ &= E_{S \sim D^m} [\hat{\mathcal{R}}_S(G)] \end{aligned} \quad (2)$$

那么我们研究函数族的复杂性有什么作用呢？它能够提供如下一个bound:

Theorem 1. 假如 G 是一个函数族，其中的函数是从 Z 到 $[0, 1]$ 区间的映射，那么对于任意 $\delta > 0$ ，至少有 $1 - \delta$ ，使得对于任意 $g \in G$ 满足：

$$E[g(z)] \leq \frac{1}{m} \sum_{i=1}^m g(z_i) + 2\mathcal{R}_m(G) + \sqrt{\frac{\log \frac{1}{\delta}}{2m}} \quad (3)$$

$$\text{and } E[g(z)] \leq \frac{1}{m} \sum_{i=1}^m g(z_i) + 2\hat{\mathcal{R}}_m(G) + 3\sqrt{\frac{\log \frac{2}{\delta}}{2m}} \quad (4)$$

在证明之前，我们先来看看这个定理想要表达的意思，根据PAC那一章节的定义，Generalization error和Empirical error分别为：

$$R(h) = \Pr_{x \sim D}[h(x) \neq c(x)] = E_{x \sim D}[1_{h(x) \neq c(x)}] \quad (5)$$

$$\hat{R}(h) = \frac{1}{m} \sum_{i=1}^m 1_{h(x_i) \neq c(x_i)} \quad (6)$$

$R(h)$ 说的假设 h 的错误率， $\hat{R}(h)$ 说的是假设 h 在这 m 个测试样本上的错误率。那么回到我们刚才的定理，给定一个假设空间 H （是一个函数族），我们可以将其转换到另一个函数族 G ，对于任意 $g \in G$ ，其对应于某一个 $h \in H$ ，有 $g(z) = g(x, y) = L(h(x), y)$ ， L 是损失函数loss function。在这里我们认为 L 为0-1 loss，也即：

$$L(y', y) = \begin{cases} 1 & y' \neq y \\ 0 & y' = y \end{cases} \quad (7)$$

那么定理中左边的 $E[g(z)]$ 就对应于 $R(h)$ ，右边的 $\frac{1}{m} \sum_{i=1}^m g(z_i)$ 对应于 $\hat{R}(h)$ 。所以定理说的其实是：

$$R(h) \leq \hat{R}(h) + 2\mathcal{R}_m(G) + \sqrt{\frac{\log \frac{1}{\delta}}{2m}}$$

由于 $R(h)$ 是很难说明的，但是 $\hat{R}(h)$ 是可以实验得到的，该bound就能利用实验得出的结果来估算 $R(h)$ 的一个上界。注意到 G 仅仅跟 L 和 H 有关，所以我们将 $2\mathcal{R}_m(G)$ 写成 H 的形式：（中间的推导基于 σ_i 是均匀分布在 $\{-1, 1\}$ 的随机变量，所以 $E[\sigma_i] = 0$ ）

$$\begin{aligned} \hat{\mathcal{R}}_S(G) &= E_{\sigma} \left[\sup_{g \in G} \frac{1}{m} \sum_{i=1}^m g(z_i) \sigma_i \right] \\ &= E_{\sigma} \left[\sup_{g \in G} \frac{1}{m} \sum_{i=1}^m \frac{1 - h(x_i) y_i}{2} \sigma_i \right] \\ &= E_{\sigma} \left[\sup_{g \in G} \frac{1}{m} \sum_{i=1}^m \frac{-h(x_i) y_i}{2} \sigma_i \right] \\ &= \frac{1}{2} E_{\sigma} \left[\sup_{g \in G} \frac{1}{m} \sum_{i=1}^m h(x_i) \sigma_i \right] = \frac{1}{2} \hat{\mathcal{R}}_{SX}(H) \end{aligned} \quad (8)$$

最后一步推导是因为，当 y_i 只能是1或-1，所以 $-y_i \sigma_i$ 也是在 $\{-1, 1\}$ 之间的均匀分布，和 σ_i 同分布，所以可以替换。由如上结论可以得到：

$$\mathcal{R}_m(G) = E_{S \sim D^m} [\hat{\mathcal{R}}_S(G)] = \frac{1}{2} \mathcal{R}_m(H) \quad (9)$$

所以到这一步，之前的定理可以转化为：

$$R(h) \leq \hat{R}(h) + \mathcal{R}_m(H) + \sqrt{\frac{\log \frac{1}{\delta}}{2m}} \quad (10)$$

$$\text{and } R(h) \leq \hat{R}(h) + \hat{\mathcal{R}}_S(H) + 3\sqrt{\frac{\log \frac{2}{\delta}}{2m}} \quad (11)$$

下面给出Theorem 1的证明：

Proof. 令 $\Phi(S) = \sup_{g \in G} E[g(z)] - \frac{1}{m} \sum_{i=1}^m g(z_i)$ ，它描述的是，相减的两个东西的差距的上界，也即求出 $\Phi(S)$ 就可以完成证明，则对于任意 S' ，如果 S' 与 S 仅有 1 个 z_k 不同，那么有：

$$\Phi(S) - \Phi(S') = \sup_{g \in G} \frac{1}{m} g(z'_k) - g(z_k) \leq \frac{1}{m} \quad (12)$$

由对称性可以知道， $\Phi(S') - \Phi(S) \leq \frac{1}{m}$ ，这时候使用 McDiarmid's inequality (之后证明)，可以得到，对于任意 $\delta > 0$ ，至少有 $1 - \delta/2$ 的概率满足：

$$\Phi(S) \leq E_S[\Phi(S)] + \sqrt{\frac{\log \frac{2}{\delta}}{2m}} \quad (13)$$

如果 $E_S[\Phi(S)]$ 是一个比较稳定的值，那么该不等式也即说明了随着样本数目 m 的增加，二者的差距在 $1 - \delta/2$ 的信心下的误差上界以根号的速度减小，接下来研究 $E_S[\Phi(S)]$ 的上界：

$$\begin{aligned} E_S[\Phi(S)] &= E_S\left[\sup_{g \in G} E[g(z)] - \frac{1}{m} \sum_{i=1}^m g(z_i)\right] \\ &= E_S\left[\sup_{g \in G} E_{S'}[\hat{E}_{S'}[g(z)]] - \hat{E}_S[g(z)]\right] \\ &= E_S\left[\sup_{g \in G} E_{S'}[\hat{E}_{S'}[g(z)] - \hat{E}_S[g(z)]]\right] \\ &\leq E_{S,S'}\left[\sup_{g \in G} (\hat{E}_{S'}[g(z)] - \hat{E}_S[g(z)])\right] \end{aligned} \quad (14)$$

最后一步用到了 $\sup_x E_y[f(x, y)] \leq E_y[\sup_x f(x, y)]$ 。

考虑到 σ_i 等概率取自 1 或 -1，由于 S 和 S' 均为随机变量，当 σ_i 给定时，根据对称性有 $E_{S,S'} \sigma_i(g(z_i) - g(z'_i)) = E_{S,S'}(g(z_i) - g(z'_i))$ ，那么也就有：

$$\begin{aligned} \text{上式} &= E_{\sigma, S, S'}\left[\sup_{g \in G} \frac{1}{m} \sum_{i=1}^m \sigma_i(g(z_i) - g(z'_i))\right] \\ &= E_{\sigma, S}\left[\sup_{g \in G} \frac{1}{m} \sum_{i=1}^m \sigma_i(g(z_i))\right] + E_{\sigma, S'}\left[\sup_{g \in G} \frac{1}{m} \sum_{i=1}^m \sigma_i(g(z'_i))\right] \\ &= 2\mathcal{R}_m(G) \end{aligned} \quad (15)$$

综上所述，至少有 $1 - \delta/2$ 的信心满足：

$$\begin{aligned}\Phi(S) &\leq E_S[\Phi(S)] + \sqrt{\frac{\log \frac{2}{\delta}}{2m}} \\ &\leq 2\mathcal{R}_m(G) + \sqrt{\frac{\log \frac{2}{\delta}}{2m}}\end{aligned}\tag{16}$$

又因为对于任意两个仅相差一个元素的 S' 和 S ， $\hat{\mathcal{R}}_S(G) - \hat{\mathcal{R}}_{S'}(G) \leq \frac{1}{m}$ ，再一次使用 McDiarmid's inequality，可以知道至少有 $1 - \delta/2$ 的信心满足：

$$E_S[\hat{\mathcal{R}}_S(G)] \leq \hat{\mathcal{R}}_S(G) + \sqrt{\frac{\log \frac{2}{\delta}}{2m}}\tag{17}$$

也即：

$$\mathcal{R}_m(G) \leq \hat{\mathcal{R}}_S(G) + \sqrt{\frac{\log \frac{2}{\delta}}{2m}}\tag{18}$$

使用 union bound 合并式上两个式子，可以至少有 $1 - \delta$ 的概率满足：

$$\Phi(S) \leq 2\hat{\mathcal{R}}_S(G) + 3\sqrt{\frac{\log \frac{2}{\delta}}{2m}}\tag{19}$$

到此为止，该定理的两个不等式都得到了证明。 \square

由于 $\mathcal{R}_m(H)$ 的计算涉及到随机变量和上确界，其计算非常困难，接下来我们引入其一个上界 growth function，它与随机变量无关，可计算性更强。

1.2 Growth function

首先引入 growth function 的定义，

Definition 3. 给定假设空间 H ，和正整数 m ，定义 *growth function* $\Pi_H : \mathbb{N} \rightarrow \mathbb{N}$ 为：

$$\Pi_H(m) = \max_{(x_1, x_2, \dots, x_m) \in \mathcal{X}} |\{(h(x_1), h(x_2), \dots, h(x_m)) | h \in H\}| \tag{20}$$

该函数定义的也是 H 的一个复杂性，给定 m 个点，用 H 中的函数去映射，能产生不超过 $|\Pi_H(m)|$ 种结果，找到 m 个点，使得该结果数最多，此时的结果数就为 $\Pi_H(m)$ 。

接下来引入 Massart's lemma，它为 Rademacher complexity 和 growth function 搭了一个重要的桥梁：

Theorem 2. 设有限集合 $A \subseteq R^m$, 令 $r = \max_{x \in A} \|x\|_2$, 则有:

$$E_\sigma \left[\frac{1}{m} \sup_{x \in A} \sum_{i=1}^m \sigma_i x_i \right] \leq \frac{r \sqrt{2 \log |A|}}{m} \quad (21)$$

其中 σ_i 独立均匀取自 $\{-1, 1\}$ 。

Proof. 定义随机变量 $Y = \sup_{x \in A} \sum_{i=1}^m \sigma_i x_i$, 函数 $f(y) = \exp(t \cdot y)$, $t > 0$, 所以有:

$$f(E[Y]) \leq E[f(Y)] \quad (22)$$

这是因为对于任意 $\alpha_1, \alpha_2, \dots, \alpha_n > 0$ 且 $\sum_i \alpha_i = 1$ 时, 有: (下凸函数性质)

$$f(\alpha_1 y_1 + \alpha_2 y_2 + \dots + \alpha_n y_n) \leq \alpha_1 f(y_1) + \alpha_2 f(y_2) + \dots + \alpha_n f(y_n) \quad (23)$$

又因为, Y 的取值最多只有 2^m 种, 故令 $n = 2^m$, $y_1 \dots y_n$ 分别对应每一种取值, 则有:

$$f(E[Y]) = f\left(\sum_{i=1}^n y_i \Pr[Y = y_i]\right) \leq \sum_{i=1}^n \Pr[Y = y_i] f(y_i) = E[f(Y)] \quad (24)$$

所以有,

$$\begin{aligned} \exp(t \cdot E[\sup_{x \in A} \sum_{i=1}^m \sigma_i x_i]) &\leq E[\exp(t \cdot \sup_{x \in A} \sum_{i=1}^m \sigma_i x_i)] \\ &= E[\sup_{x \in A} \exp(\sum_{i=1}^m t \cdot \sigma_i x_i)] \\ &\leq \sum_{x \in A} E[\exp(\sum_{i=1}^m t \cdot \sigma_i x_i)] \\ &= \sum_{x \in A} \prod_{i=1}^m E[\exp(t \sigma_i x_i)] \end{aligned} \quad (25)$$

上述推导用了求和来放缩 \sup , 并且 σ_i 之间相互独立, 继续放缩右边的式子:

$$E[\exp(t \sigma_i x_i)] \leq \exp\left(\frac{t^2 (2r)^2}{8}\right) \quad (26)$$

这是因为 $\sigma_i x_i \in [-x_i, x_i]$, 令 $a = -x_i, b = x_i$, 由凸函数性质有:

$$\exp(t \sigma_i x_i) \leq \frac{b - \sigma_i x_i}{b - a} \exp(ta) + \frac{\sigma_i x_i - a}{b - a} \exp(tb) \quad (27)$$

两边取期望得到:

$$E[e^{t \sigma_i x_i}] \leq e^{ta} E\left[\frac{b - \sigma_i x_i}{b - a}\right] + e^{tb} E\left[\frac{\sigma_i x_i - a}{b - a}\right] \quad (28)$$

由于 $E[\sigma_i x_i] = 0$ 所以上式子可以写成:

$$\begin{aligned} E[e^{t\sigma_i x_i}] &\leq e^{ta} \frac{b}{b-a} + e^{tb} \frac{-a}{b-a} \\ &\leq e^{\phi(t)} \end{aligned} \quad (29)$$

$$\begin{aligned} \phi(t) &= \log(e^{ta} \frac{b}{b-a} + e^{tb} \frac{-a}{b-a}) \\ &= ta + \log(\frac{b}{b-a} + e^{tb-ta} \frac{-a}{b-a}) \\ &= \phi(0) + t\phi'(0) + \frac{t^2}{2}\phi''(\theta) \\ &= t^2 \frac{(b-a)^2}{8} \end{aligned} \quad (30)$$

最后一步是暴力泰勒展开得到的, 所以得到:

$$E[e^{t\sigma_i x_i}] \leq \exp(t^2 \frac{(b-a)^2}{8}) = \exp(t^2 \frac{x_i^2}{2}) \quad (31)$$

$$\begin{aligned} \exp(t \cdot E[\sup_{x \in A} \sum_{i=1}^m \sigma_i x_i]) &\leq \sum_{x \in A} \exp(t^2 r^2 / 2) \\ &\leq |A| \exp(t^2 r^2 / 2) \end{aligned} \quad (32)$$

$$(t \cdot E[\sup_{x \in A} \sum_{i=1}^m \sigma_i x_i]) \leq (\frac{t^2 r^2}{2}) + \log |A| \quad (33)$$

$$E[\sup_{x \in A} \sum_{i=1}^m \sigma_i x_i] \leq (\frac{tr^2}{2}) + \frac{\log |A|}{t} \quad (34)$$

取 $t = \sqrt{\frac{2 \log |A|}{r^2}}$ 可以得到右边最小值为 $\sqrt{2 \log |A|} r$, 此时得到:

$$E[\sup_{x \in A} \sum_{i=1}^m \sigma_i x_i] \leq \sqrt{2 \log |A|} r \quad (35)$$

$$\frac{1}{m} E[\sup_{x \in A} \sum_{i=1}^m \sigma_i x_i] \leq \frac{r \sqrt{2 \log |A|}}{m} \quad (36)$$

定理得证。

□

我们尝试把 $\mathcal{R}_m(H)$ 和 $\Pi_H(m)$ 建立联系，首先假设 H 中的函数 h 将点映射到 $\{-1, 1\}$ ，则：

$$\mathcal{R}_m(H) = E_{S \sim D^m} [E_{\sigma} [\sup_{h \in H} \frac{1}{m} \sum_{i=1}^m \sigma_i h(z_i)]] \quad (37)$$

使用Theorem2，把 H_S 看成 A 可以得到：

$$\begin{aligned} \mathcal{R}_m(H) &\leq E_{S \sim D^m} \left[\frac{r \sqrt{2 \log |H_S|}}{m} \right] \\ &\leq \frac{r \sqrt{2 \log \Pi_H(m)}}{m} \end{aligned} \quad (38)$$

其中当 S 给定时 $r = \max_{h \in H} \{\|(h(x_1), h(x_2), \dots, h(x_m))\|_2\}$ ，我们假设 H 中的函数映射到 $\{-1, 1\}$ ，那么有 $r \leq \sqrt{m}$ 对任意 $S \sim D^m$ 成立。

所以在这种假定下，上式可以写成：

$$\mathcal{R}_m(H) \leq \sqrt{\frac{2 \log \Pi_H(m)}{m}} \quad (39)$$

所以前一小节的bound可以被写为：

$$\begin{aligned} R(h) &\leq \hat{R}(h) + \mathcal{R}_m(H) + \sqrt{\frac{\log \frac{1}{\delta}}{2m}} \\ &\leq \hat{R}(h) + \sqrt{\frac{2 \log \Pi_H(m)}{m}} + \sqrt{\frac{\log \frac{1}{\delta}}{2m}} \end{aligned} \quad (40)$$

1.3 VC-dimension

前面提到的growth function虽然说不依赖于随机变量，但是计算仍然相当困难，接下来引入另外一个用来衡量假设空间 H 的复杂性的指标，VC-dimension。它的定义如下：

Definition 4. 一个假设空间 H 的VC-dimension被定义为，最大的可能被 H 完全打散的数据的大小，也即：

$$VCdim(H) = \max\{m : \Pi_H(m) = 2^m\} \quad (41)$$

它的定义蕴含了两个意思：

1. 对于任意 $m \leq VCdim(H)$ ，存在一个 $S = (x_1, x_2, \dots, x_m)$ ，使得 $|H|_S| = 2^m$ 。
2. 对于任意 $m > VCdim(H)$ ，不存在 $S = (x_1, x_2, \dots, x_m)$ ，使得 $|H|_S| = 2^m$ 。

下面我们将 $VCdim(H)$ 和 $\Pi_H(m)$ 建立联系, 这样我们就可以将之前的bound用 $VCdim(H)$ 来表示。

首先引入一个定理:

Theorem 3. 设假设空间 H 的 $VCdim(H) = d$, 那么对于任意 $m \in \mathbb{N}$, 有如下不等式成立:

$$\Pi_H(m) \leq \sum_{i=0}^d \binom{m}{i} \quad (42)$$

Proof. 对 $m + d$ 的大小归纳, 这么归纳的目的是为了用如下性质:

$$\binom{m}{i} = \binom{m-1}{i} + \binom{m-1}{i-1} \quad (43)$$

利用该性质我们可以得到:

$$\sum_{i=0}^d \binom{m-1}{i} + \sum_{i=0}^{d-1} \binom{m-1}{i} = \sum_{i=0}^d \binom{m}{i} \quad (44)$$

接下来我们按照两重循环求组合数的顺序(先枚举 m , 再枚举 d) 来归纳证明:

1. 基础: $m = 1$ 时, $d = 0, d = 1$ 都有结论成立。
2. 归纳: $m \geq 2$ 时, 若 $d = 0$ 则结论成立, 否则令 S 为满足 $|H|_S| = \Pi_H(m)$ 的一个Sample。令 G 表示将 H 约束到 S 上的函数集合(将 H 定义域改成 S), 有 $|G| = \Pi_H(m)$ 。

下面我们将 G 分割成两个假设空间 G_1 和 G_2 , 使得 $VCdim(G_1) \leq d, VCdim(G_2) \leq d - 1$, 且有 $|G_1| \leq \Pi_{G_1}(m - 1), |G_2| \leq \Pi_{G_2}(m - 1)$, 就能完成归纳:

先约定 $H : \mathcal{X} \rightarrow \{0, 1\}, S' = (x_1, x_2, \dots, x_{m-1})$,

那么令 G_1 为将 H 约束到 S' 上的函数集合, 也就是在 G 中只看前 $m - 1$ 个点的分类结果来去重。

我们在 G 中找到两个函数 g_1, g_2 , 使得它们约束到 S' 上都是一样的, 那么有它们对 x_m 的分类就一个是0, 一个是1。我们把分类是0的那个函数扔到 G'_2 里。

我们将 G 中的函数, 按照其在 S' 的取值作为key, G 中每个key恰好在 G_1 中出现一次, G 中每个出现2次的key都恰好在 G'_2 出现一次。

所以有 $|G_1| + |G'_2| = |G|$, 再让 G_2 为将 G'_2 约束到 S' 的结果, 一定有 $|G_2| = |G'_2|$, 故替换后有 $|G_1| + |G_2| = |G|$ 。

由于 G_1, G_2 ，考虑到 G_1, G_2 大小都等于自己作用在 S' 上的大小，由growth function定义有：

$$|G_1| \leq \Pi_{G_1}(m-1) \quad (45)$$

$$|G_2| \leq \Pi_{G_2}(m-1) \quad (46)$$

由于 $G_1 \subseteq H$ ，肯定有 $VCdim(G_1) \leq VCdim(H) = d$ ，又因为 G_2 的定义域是 S' ，我们假设其VCdim为 k ，那么 G_2 的极限也就是能把 $S_k \subseteq S'$ 中的元素全部打散，往 S_k 中加入 x_m ，这时 H 就可以打散，但是 G_2 不可以打散。所以有 $VCdim(G_2) \leq VCdim(H) - 1 = d - 1$ 。

所以有：

$$|G_1| \leq \Pi_{G_1}(m-1) \leq \sum_{i=0}^d \binom{m-1}{i} \quad (47)$$

$$|G_2| \leq \Pi_{G_2}(m-1) \leq \sum_{i=0}^{d-1} \binom{m-1}{i} \quad (48)$$

$$\Pi_H(m) = |G| = |G_1| + |G_2| \leq \sum_{i=0}^d \binom{m}{i} \quad (49)$$

□

然后我们把组合数求和变成一个容易求的上界，如果 $(m \geq d)$ ，

$$\begin{aligned} \Pi_H(m) &\leq \sum_{i=0}^d \binom{m}{i} \\ &\leq \sum_{i=0}^d \binom{m}{i} \left(\frac{m}{d}\right)^{d-i} \\ &\leq \sum_{i=0}^m \binom{m}{i} \left(\frac{m}{d}\right)^{d-i} \\ &= \left(\frac{m}{d}\right)^d \sum_{i=0}^m \binom{m}{i} \left(\frac{d}{m}\right)^i \\ &= \left(\frac{m}{d}\right)^d \left(1 + \frac{d}{m}\right)^m \\ &= \left(\frac{m}{d}\right)^d \left(1 + \frac{d}{m}\right)^{m/d \cdot d} \\ &\leq \left(\frac{em}{d}\right)^d \end{aligned} \quad (50)$$

推导中比较巧妙的地方在于，凭空加入 $(\frac{m}{d})^{d-i}$ 这一项，凑出来一个二项式求和，反向使用二项式定理，然后用自然对数 e 的展开就很自然了。

到了这一步，我们可以将之前的bound改成，如果 $m \geq d$ ，对于某VCdim为 d 的假设空间 H ，有 $1 - \delta$ 的信心满足：

$$\begin{aligned} R(h) &\leq \hat{R}(h) + \sqrt{\frac{2 \log \Pi_H(m)}{m}} + \sqrt{\frac{\log \frac{1}{\delta}}{2m}} \\ &\leq \hat{R}(h) + \sqrt{\frac{2d \log(\frac{em}{d})}{m}} + \sqrt{\frac{\log \frac{1}{\delta}}{2m}} \\ &\leq \hat{R}(h) + O\left(\sqrt{\frac{\log(m/d)}{(m/d)}}\right) \end{aligned} \quad (51)$$

接下来介绍一个结论：

Theorem 4. 所有 n 维的超平面分类函数构成的集合 H_n 的VCdim为 $n + 1$ 。

一个 n 维超平面可以用一个 n 维向量 $w = (w_1, w_2, \dots, w_n)^T$ 和一个实数 b 表示，该平面由 $w \cdot x = b$ 确定。所以对于该超平面分类器对点 x 的分类为 $\text{sgn}(w \cdot x - b)$ ，下面给出上述定理的证明：

Proof. 令 $m = n + 1$ ，构造 $S_X = (x_0, x_1, \dots, x_n)$ ，其中 x_0 为原点， x_i 为 n 维one-hot向量，第 i 维为1。则对于任意 $S_Y = (y_0, y_1, \dots, y_n)$ ， $y_i \in \{-1, 1\}$ ，则令 $w = (y_1, y_2, \dots, y_n)$ ， $b = y_0/2$ ，则有：

$$\text{sgn}(w \cdot x_i - b) = \text{sgn}(y_i - y_0/2) = y_i \quad (52)$$

对所有 $0 \leq i \leq n$ 成立，所以证明了存在一个包含 $n + 1$ 个点的sample使得其能被 H_n 打散，接下来证明 H_n 无法打散任意一个大小为 $n + 2$ 的sample。

这需要利用到一个性质，对于任意一个 $S = (x_1, x_2, \dots, x_{n+2})$ ，一定存在其一个划分 S_1 和 S_2 ，使得 S_1 的凸壳与 S_2 的凸壳相交。有这条性质的话，我们假设可以找到一个超平面分类器能分类 S_1 和 S_2 ，那么该平面肯定分开了该凸壳，得到这两个凸壳不可能相交，于是产生矛盾，就证明了结论。

那么下面来证明上述性质，我们考虑方程组：

$$\sum_{i=1}^{d+2} \alpha_i x_i = 0 \quad \text{and} \quad \sum_{i=1}^{d+2} \alpha_i = 0 \quad (53)$$

该方程组有 $d + 2$ 个未知数 $\alpha_{1\dots d+2}$ ，和 $d + 1$ 个方程，所以肯定有非零解 $\beta_1, \dots, \beta_{d+2}$ ，那么令

$$I_1 = \{i \in [1, d + 2] : \beta_i > 0\} \quad (54)$$

$$I_2 = \{i \in [1, d + 2] : \beta_i < 0\} \quad (55)$$

$$\beta = \sum_{i \in I_1} \beta_i \quad (56)$$

则有：

$$\sum_{i \in I_1} \frac{\beta_i}{\beta} x_i = - \sum_{i \in I_2} \frac{\beta_i}{\beta} x_i \quad (57)$$

由凸壳的定义(书上B.4)可以知道，点 $\sum_{i \in I_1} \frac{\beta_i}{\beta} x_i$ 即在 I_1 下标里的点构成的凸壳里，也在 I_2 下标里的点构成的凸壳里。□

2 Boosting

2.1 Introduction

这一章节讲述的Boosting是一种将多个弱的分类器合成出一个强的分类器的方法。PAC-learnable的条件对我们来说太过苛刻，我们不妨放低一点标准，所以引入一个新的概念：

Definition 5 (Weak learning). 如果一个 *Concept Class* C ，满足存在一个算法 A ，和一个常数 $\gamma > 0$ ，一个固定的多项式 $\text{poly}(\cdot, \cdot, \cdot, \cdot)$ 使得对于任意 $\epsilon > 0$ 和 $\delta > 0$ ，以及任意分布 D ，和任意给定 $c \in C$ ，当 $m \geq \text{poly}(1/\epsilon, 1/\delta, n, \text{size}(c))$ 时：

$$\Pr_{S \sim D^m} \left[R(h_s) \leq \frac{1}{2} - \gamma \right] \geq 1 - \delta \quad (58)$$

简单来说，存在一个学习concept class C 的算法 A ，使得当训练数据越来越多的时候，算法 A 返回的分类器错误率小于 $\frac{1}{2}$ 的概率趋近于1。这样的算法被称为weak learning algorithm，其返回的分类器(也就是 $h \in H$)成为base classifiers。

Boost的中心思想就是运用weak learning algorithm去构造一个strong learner，接下来就来介绍AdaBoost。

2.1.1 AdaBoost

AdaBoost算法如下所示：

Algorithm 1 AdaBoost($S = ((x_1, y_1), (x_2, y_2), \dots, (x_m, y_m))$)

```

1: for  $i = 1 \rightarrow m$  do
2:    $D_1(i) \leftarrow \frac{1}{m}$ 
3: end for
4: for  $t = 1 \rightarrow T$  do
5:    $h_t \leftarrow$  base classifier in  $H$  with small error  $\epsilon_t = \Pr_{i \sim D_t} [h(x_i) \neq y_i]$ 
6:    $\alpha_t \leftarrow \frac{1}{2} \log \frac{1-\epsilon_t}{\epsilon_t}$ 
7:    $Z_t \leftarrow 2[\epsilon_t(1-\epsilon_t)]^{\frac{1}{2}}$ 
8:   for  $i = 1 \rightarrow m$  do
9:      $D_{t+1}(i) \leftarrow \frac{D_t(i) \exp(-\alpha_t y_i h_t(x_i))}{Z_t}$ 
10:  end for
11: end for
12:  $g \leftarrow \sum_{t=1}^T \alpha_t h_t$ 
13: return  $h = \text{sgn}(g)$ 

```

算法简单来看其实就是迭代 T 次，第 t 次迭代找到在分布 D_t 下错误率 ϵ_t 最小的 $h_t \in H$ ，根据 ϵ_t 得到 h_t 在 g 中的比例 α_t ，并计算 D_{t+1} 开始下一次迭代。

首先来看 $\alpha_t = \frac{1}{2} \log \frac{1-\epsilon_t}{\epsilon_t}$ ，由于 $h_t \in H$ 是base classifier，所以 $\epsilon_t < \frac{1}{2}$ ，也就有 $\alpha_t > 0$ ，而且错误率 ϵ_t 越小， α_t 越大，也符合直觉。

再来看分布 D_t 如何计算，一开始 $D_1(i) = \frac{1}{m}$ 为均匀分布。之后更新 D_t 的策略是减少 $h_t(x_i) = y_i$ 的分布，而增加 $h_t(x_i) \neq y_i$ 的分布，也就是多“练习”错误的“题”才有进步的空间。

Z_t 是一个归一化因子，也即：

$$2[\epsilon_t(1-\epsilon_t)]^{\frac{1}{2}} = \sum_{i=1}^m D_t(i) \exp(-\alpha_t y_i h_t(x_i)) \quad (59)$$

接下来说明上式的正确性，由于：

$$\alpha_t = \frac{1}{2} \log \frac{1-\epsilon_t}{\epsilon_t} \quad (60)$$

将该结果代入要证明的结论的右边得到：

$$\begin{aligned}
\text{右边} &= \sum_{i=1}^m D_t(i) \exp(-\alpha_t y_i h_t(x_i)) \\
&= \sum_{i=1}^m D_t(i) \left(\frac{1-\epsilon_t}{\epsilon_t} \right)^{\frac{-1}{2} y_i h_t(x_i)} \\
&= \sum_{y_i \neq h_t(x_i)} D_t(i) \left(\frac{1-\epsilon_t}{\epsilon_t} \right)^{1/2} + \sum_{y_i = h_t(x_i)} D_t(i) \left(\frac{1-\epsilon_t}{\epsilon_t} \right)^{-1/2} \\
&= \epsilon_t \left(\frac{1-\epsilon_t}{\epsilon_t} \right)^{1/2} + (1-\epsilon_t) \left(\frac{1-\epsilon_t}{\epsilon_t} \right)^{-1/2} \\
&= 2(\epsilon_t(1-\epsilon_t))^{1/2} = \text{左边}
\end{aligned} \tag{61}$$

接下来我们给出 $\hat{R}(g)$ 的一个上界：

Theorem 5. AdaBoost得到的 g 的empirical error 满足：

$$\hat{R}(g) \leq \exp \left[-2 \sum_{t=1}^T \left(\frac{1}{2} - \epsilon_t \right)^2 \right] \tag{62}$$

由该定理可以知道， ϵ_t 越小的话，上界就会越紧，所以我们要选择 ϵ_t 尽量小的 h_t ，在证明该定理之前，需要一个结论来辅助：

$$D_{t+1}(i) = \frac{e^{-y_i g_t(x_i)}}{m \prod_{s=1}^t Z_s} \tag{63}$$

其中 $g_t = \sum_{s=1}^t g_s \alpha_s$ ，可以用归纳法证明该结论：

1. 基础： $t = 1$ 时， $D_2(i) = \frac{D_1(i) \exp(-\alpha_1 y_i h_1(x_i))}{Z_1} = \frac{\exp(-y_i g_1(x_i))}{m Z_1}$ 。
2. 归纳：假设结论对 $1, 2, \dots, t-1$ 成立，由算法的定义有：

$$D_{t+1}(i) = \frac{D_t(i) \exp(-\alpha_t y_i h_t(x_i))}{Z_t} \tag{64}$$

由归纳假设可以知道：

$$D_t(i) = \frac{\exp(-y_i g_{t-1}(x_i))}{m \prod_{s=1}^{t-1} Z_s} \tag{65}$$

代入上式可以得到：

$$\begin{aligned}
D_{t+1}(i) &= \frac{\exp(-(\alpha_t y_i h_t(x_i) + y_i g_{t-1}(x_i)))}{m \prod_{s=1}^t Z_s} \\
&= \frac{\exp(-y_i g_t(x_i))}{m \prod_{s=1}^t Z_s}
\end{aligned} \tag{66}$$

所以归纳成立。

有了这个结论，现在证明上述定理：

Proof. 由empirical error 的定义可以知道， $\hat{R}(g) = \frac{1}{m} \sum_{i=1}^m 1_{g(x_i) \neq y_i}$ ，所以有：

$$\begin{aligned} \hat{R}(g) &= \frac{1}{m} \sum_{i=1}^m 1_{g(x_i) \neq y_i} \\ &\leq \frac{1}{m} \sum_{i=1}^m e^{-g(x_i)y_i} \end{aligned} \quad (67)$$

由于 $\sum_{i=1}^m D_{T+1}(i) = 1 = \sum_{i=1}^m \frac{\exp(-y_i g_T(x_i))}{m \prod_{s=1}^T Z_s}$ ，所以有：

$$\sum_{i=1}^m \frac{1}{m} \exp(-y_i g_T(x_i)) = \prod_{s=1}^T Z_s = \prod_{s=1}^T 2[\epsilon_s(1 - \epsilon_s)]^{\frac{1}{2}} \quad (68)$$

代入上式可以得到：

$$\begin{aligned} \hat{R}(g) &\leq \frac{1}{m} \sum_{i=1}^m e^{-g(x_i)y_i} \\ &\leq \prod_{s=1}^T 2[\epsilon_s(1 - \epsilon_s)]^{\frac{1}{2}} \\ &= \prod_{s=1}^T 2\sqrt{-\left(\epsilon_s - \frac{1}{2}\right)^2 + \frac{1}{4}} \\ &= \prod_{s=1}^T \sqrt{1 - 4\left(\epsilon_s - \frac{1}{2}\right)^2} \\ &\leq \prod_{s=1}^T e^{-2\left(\epsilon_s - \frac{1}{2}\right)^2} \\ &= \exp\left[\sum_{s=1}^T -2\left(\epsilon_s - \frac{1}{2}\right)^2\right] \end{aligned} \quad (69)$$

□

所以从这个结论我们可以看到，随着迭代次数 T 的增加， $\hat{R}(g)$ 会越来越小，但不意味着 $R(g)$ 就会越来越小，也即我们不仅要考虑 $\hat{R}(g)$ 还需要考虑它和 $R(g)$ 的差距，我们先得到 g 的假设空间 \mathcal{F}_T ：

$$\mathcal{F}_T = \left\{ \text{sgn} \left(\sum_{t=1}^T \alpha_t h_t \right) : \alpha_t \in \mathbb{R}, h_t \in H, t \in [1, T] \right\} \quad (70)$$

由书上结论，可以知道

$$VCdim(\mathcal{F}_T) \leq 2(d+1)(T+1)\log_2((T+1)e) \quad (71)$$

其中 $d = VCdim(H)$ 。从这个式子可以看出， $VCdim(\mathcal{F}_T)$ 按 $O(T \log T)$ 增长，由前面VCdim的性质可以知道， $\hat{R}(g)$ 和 $R(g)$ 的差距在不断增大，也就是说随着迭代次数的增多，可能导致Overfit。

3 Dimensionality Reduction

3.1 Principal Component Analysis

我们经常用一个 n 维的向量来描述一个事物，比如说一个单词，一张图片。那么有时候 n 太大导致处理太困难。希望能将数据重新表示成一个 k 维（ k 远远小于 n ）的向量。比如有100个2维向量，恰好都落在一条直线上，那么只需要一个Pd，加上100个实数就可以表示，但是一般情况下数据不可能恰好落在一条直线上。那么想把这100个点从二维降到一维，就必须要有损失。那么一个直观的做法就是，找到一条直线，使得这100个点离这条直线的偏离最小，然后对于某个点，它的降维后的结果就是在这个直线上的投影。

3.1.1 奇异值分解(Singular Value Decomposition)

首先需要约定一下奇异值分解SVD的形式（与线性代数(下)有点不同），对于一个 n 行 m 列的矩阵 A ，设其SVD分解为：

$$A = U\Sigma V^T \quad (72)$$

其中 $U = (u_1, u_2, \dots, u_r)$ 是一个 n 行 r 列的矩阵， r 为 A 的秩(rank)， Σ 为 r 行 r 列的对角方阵。 V 为 m 行 r 列的矩阵。

满足 U 中 r 个列向量两两正交，也即有 $U^T U = I_r$ ，类似地有 $V^T V = I_r$ 。

3.1.2 正交投影矩阵(orthogonal projection matrix):

给定 k 个相互正交的 n 维向量 (a_1, a_2, \dots, a_k) 构成一组基 A ，则对于给定任意 n 维向量 b ，分别求解 b 在 a_i 上的投影长度 x_i ，再合成得到其投影向量 $p = \sum_{i=1}^k a_i x_i$ 。由于 $x_i = \frac{a_i^T b}{a_i^T a_i}$ ，故可以得到：

$$p = \left(\sum_{i=1}^k \frac{a_i a_i^T}{a_i^T a_i} \right) b \quad (73)$$

令 $P = \sum_{i=1}^k \frac{a_i a_i^T}{a_i^T a_i}$, $U_k = (\frac{a_1}{\sqrt{a_1^T a_1}}, \dots, \frac{a_k}{\sqrt{a_k^T a_k}})$, 则有:

$$P = U_k U_k^T \quad (74)$$

P 就是正交投影矩阵, 正交表示其对应的基 A 是正交的, 投影矩阵的意思就是用 P 左乘某个向量 b 就可以得到其在 A 上的投影 p 。那么一个正交投影矩阵满足以下性质:

1. $P^T = P$: 由公式(2)可以得到。
2. $P^2 = P$: 一个向量投影到 A 上之后, 再投影还是这个向量。

3.1.3 PCA

假定输入数据为 $X = (x_1, x_2, \dots, x_m)$, X 是一个 $n \times m$ 的矩阵, 我们希望将其降至 k 维, 并且使得受到的损失最小, 也即找到一个正交投影矩阵 P^* (P^* 对应 k 个 n 维正交基), 满足:

$$P^* = \arg \min_P \|PX - X\|_F \quad (75)$$

也就是投影后, 两个矩阵的差距最小, 由于:

$$\begin{aligned} \|PX - X\|_F^2 &= \text{Tr}((PX - X)^T(PX - X)) \\ &= \text{Tr}(X^T P^T P X - X^T P X - X^T P^T X - X^T X) \\ &= \text{Tr}(-X^T P X - X^T X) \\ &= \text{Tr}(-X^T P X) - \text{Tr}(X^T X) \end{aligned} \quad (76)$$

上述推导用到了 $P^T = P$, $P^2 = P$, 和矩阵迹 Tr 算符的线性性质。由于 X 是给定的, 所以: (假设 $P = U_k U_k^T$, U_k 为 $n \times k$ 矩阵, 且列向量互相正交)。

$$\begin{aligned} P^* &= \arg \min_P \|PX - X\|_F \\ &= \arg \max_P \text{Tr}(X^T P X) \\ &= \arg \max_{U_k} \text{Tr}((X^T U_k)((X^T U_k)^T)) \\ &= \arg \max_{U_k} \text{Tr}(U_k^T (X X^T) U_k) \\ &= \arg \max_{U_k} \sum_{i=1}^k u_i^T (X X^T) u_i \end{aligned} \quad (77)$$

令 $C = X X^T$, 取 u_i 为将 C 奇异值分解后, 第 i 个左奇异值向量(left singular vector)。则可以得到最优解 U_k , 所以 $PX = U_k U_k^T X$, 令 $Y = U_k^T X$, 就得到降维后的向量。(后面可以看到, 其实左右奇异值向量是一样)

下面解释原理，假设 X 的奇异值分解为：

$$X = U\Sigma V^T \quad (78)$$

那么有：

$$\begin{aligned} XX^T &= U\Sigma V^T V \Sigma^T U^T \\ &= U\Sigma \Sigma^T U^T \\ &= \sum_{i=1}^r \sigma_i^2 u_i u_i^T \end{aligned} \quad (79)$$

所以有 $u_1 XX^T u_1^T = \sigma_1^2$ 最大， $u_2 XX^T u_2^T = \sigma_2^2$ 次大.....

3.2 Kernel Principal Component Analysis

有时候在 n 维下，线性分类无法区分一类概念，但是将其映射到更高的维度就可以了。本来我们是直接把数据从 n 维降到 k 维，现在我们是将数据先映射到一个更高的维度的Hilbert space（定义了内积的空间），然后再降到 k 维。我们设这样的映射为 $\Phi(x)$ ，令映射后的数据为 $X = (\Phi(x_1), \Phi(x_2), \dots, \Phi(x_m))$ ，然后对 X' 套用PCA即可。

不过我们有时候并不需要知道映射 $\Phi(x)$ 是什么，我们只需要知道一个Kernel Matrix K ，它表示两两元素的在高维空间的内积。假设我们已经把数据映射后得到了 X ，注意这时候 X 就不是 n 行， m 列了（因为维度更高）。那么我们可以定义 $K = X^T X$ （注意这里的矩阵乘法，内积由其所在的高维空间定义，但是由于内积的性质，我们依然可以套用原来的写法）。

直接对 X 进行PCA，也就是对 XX^T 进行SVD，我们假设 X 的SVD为 $X = U\Sigma V^T$ ，那么有 $XX^T = U\Sigma^2 U^T$ ， $K = V\Sigma^2 V^T$ 。令 $\Lambda = \Sigma^2$ ， λ_i 表示第 i 个对角元素。

我们的目标是，将降维结果 Y 能用 K 表示，而不是 X 的形式。由之前的结论：

$$Y = U_k^T X \quad (80)$$

那么我们先吧 U_k 试着用 K 来表示，我们把 $X = U\Sigma V^T$ 两边同时右乘 $V\Sigma^{-1}$ 得到 $U = XV\Sigma^{-1}$ （ Σ 是可逆的），改写一下：

$$\begin{aligned} U &= XV\Lambda^{-1/2} \\ &= X\left(\frac{v_1}{\sqrt{\lambda_1}}, \frac{v_2}{\sqrt{\lambda_2}}, \dots, \frac{v_r}{\sqrt{\lambda_r}}\right) \end{aligned} \quad (81)$$

所以有:

$$U_k = (X \frac{v_1}{\sqrt{\lambda_1}}, X \frac{v_2}{\sqrt{\lambda_2}}, \dots, X \frac{v_k}{\sqrt{\lambda_k}}) \quad (82)$$

带入得到:

$$\begin{aligned} Y &= U_k^T X \\ &= (X \frac{v_1}{\sqrt{\lambda_1}}, X \frac{v_2}{\sqrt{\lambda_2}}, \dots, X \frac{v_k}{\sqrt{\lambda_k}})^T X \\ &= (X^T X \frac{v_1}{\sqrt{\lambda_1}}, X^T X \frac{v_2}{\sqrt{\lambda_2}}, \dots, X^T X \frac{v_k}{\sqrt{\lambda_k}})^T \\ &= (K \frac{v_1}{\sqrt{\lambda_1}}, K \frac{v_2}{\sqrt{\lambda_2}}, \dots, K \frac{v_k}{\sqrt{\lambda_k}})^T \end{aligned} \quad (83)$$

由特征向量性质 $Kv_i = \lambda_i v_i$, 代入得到:

$$Y = (\sqrt{\lambda_1} v_1, \sqrt{\lambda_2} v_2, \dots, \sqrt{\lambda_k} v_k)^T \quad (84)$$

也就是给定核矩阵 K , 就能够求出原 m 个数据的降维表示。

3.3 Johnson-Lindenstrauss lemma

该引理说的是, 对于 m 个 n 维的点, 可以用一个映射将其降维至 k ($k \geq O(\frac{\log m}{\epsilon^2})$), 同时满足任意两点之间的距离比原来不超过 $(1 \pm \epsilon)$ 倍。下面开始证明:

Lemma 6. 假定 Q 服从自由度为 k 的卡方分布, 则对于任意 $0 < \epsilon < 1/2$, 有如下不等式成立:

$$\Pr[(1 - \epsilon)k \leq Q \leq (1 + \epsilon)k] \geq 1 - 2e^{-(\epsilon^2 - \epsilon^3)k/4} \quad (85)$$

Proof. 正难则反, 先计算 Q 在取值范围外的概率, 再减去。

$$\begin{aligned} \Pr[Q \geq (1 + \epsilon)k] &= \Pr[\exp(\lambda Q) \geq \exp(\lambda(1 + \epsilon)k)] \\ &\leq \frac{E[\exp(\lambda Q)]}{\exp(\lambda(1 + \epsilon)k)} \end{aligned} \quad (86)$$

$$E[\exp(\lambda Q)] = \prod_{i=1}^k E[e^{\lambda X_i^2}] \quad (87)$$

$$\begin{aligned} E[e^{\lambda X_i^2}] &= \int_{-\infty}^{\infty} \frac{e^{\lambda t^2}}{\sqrt{2\pi}} e^{-t^2/2} dt \\ &= \frac{1}{\sqrt{1 - 2\lambda}} \end{aligned} \quad (88)$$

式(17)要求 $Re(\lambda) < 1/2$ 。所以(15)可以继续写成：

$$\Pr[Q \geq (1 + \epsilon)k] \leq \frac{(1 - 2\lambda)^{-k/2}}{\exp(\lambda(1 + \epsilon)k)} \quad (89)$$

将等式右边对 λ 求导，并令导数等于0，得到：

$$\lambda^* = \frac{\epsilon}{2(\epsilon + 1)} < 1/2 \quad (90)$$

带入 λ^* 得到：

$$\Pr[Q \geq (1 + \epsilon)k] \leq \left(\frac{1 + \epsilon}{\exp(\epsilon)}\right)^{k/2} \quad (91)$$

考虑到

$$\begin{aligned} \exp(\epsilon - (\epsilon^2 - \epsilon^3)/2) &\geq 1 + [\epsilon - (\epsilon^2 - \epsilon^3)/2] + [\epsilon - (\epsilon^2 - \epsilon^3)/2]^2/2 \\ &= (1 + \epsilon + (5\epsilon^4)/8 - \epsilon^5/4 + \epsilon^6/8) \\ &\geq 1 + \epsilon \end{aligned} \quad (92)$$

故有：

$$\Pr[Q \geq (1 + \epsilon)k] \leq \exp(-k(\epsilon^2 - \epsilon^3)/4) \quad (93)$$

类似可以证明：

$$\Pr[Q \leq (1 - \epsilon)k] \leq \exp(-k(\epsilon^2 - \epsilon^3)/4) \quad (94)$$

由Union bound可以得到引理成立。 \square

Lemma 7. 给定 n 维向量 x ，和一个 k 行 n 列的矩阵 A ，保证 A 中的元素均独立同 $N(0, 1)$ 分布，那么对于任意 $0 < \epsilon < 1/2$ 有：

$$\Pr[(1 - \epsilon) \|x\|^2 \leq \left\| \frac{1}{\sqrt{k}} Ax \right\|^2 \leq (1 + \epsilon) \|x\|^2] \geq 1 - 2e^{-(\epsilon^2 - \epsilon^3)k/4} \quad (95)$$

Proof.

上式左边

$$= \Pr[(1 - \epsilon)k \leq \|Ax\|^2 / \|x\|^2 \leq (1 + \epsilon)k] \quad (96)$$

令 $\hat{x} = Ax$ ， $T_j = \hat{x}_j / \|x\|$ ，有 T_j 服从 $N(0, 1)$ ，故得到 $Q = \sum_{i=1}^k T_j^2$ 服从自由度为 k 的卡方分布。由Lemma6 可以得到结论成立。 \square

Lemma 8 (Johnson-Lindenstrauss). 对于任意 $0 < \epsilon < 1/2$, 和任意整数 $m > 4$, 令 $k = \frac{20 \log m}{\epsilon^2}$. 则对于任意 n 为空间的 m 个点构成的集合 V , 存在一个映射 $f : R^n \rightarrow R^k$, 使得对于任意 $u, v \in V$,

$$(1 - \epsilon) \|u - v\|^2 \leq \|f(u) - f(v)\|^2 \leq (1 + \epsilon) \|u - v\|^2 \quad (97)$$

Proof. 我们将 V 中的点, 标号为 v_1, v_2, \dots, v_m , 令事件 A_{ij} 表示 $x = v_i - v_j$ 满足 Lemma 7 的不等式。则只要能说明:

$$\Pr\left[\bigcap_{1 \leq i < j \leq m} A_{ij}\right] > c \quad (98)$$

其中 c 为一给定大于 0 的常数。由 Lemma 2 可知,

$$\Pr[A_{ij}^C] = 1 - \Pr[A_{ij}] \leq 2e^{-(\epsilon^2 - \epsilon^3)k/4} \quad (99)$$

所以可以得到:

$$\begin{aligned} \Pr\left[\bigcap_{1 \leq i < j \leq m} A_{ij}\right] &= 1 - \Pr\left[\bigcup_{1 \leq i < j \leq m} A_{ij}^C\right] \\ &\geq 1 - \sum_{1 \leq i < j \leq m} \Pr[A_{ij}^C] \\ &\geq 1 - (m-1)m/2 * 2e^{-(\epsilon^2 - \epsilon^3)k/4} \end{aligned} \quad (100)$$

取 $\epsilon = 1/2$ 上式概率取到最小, 当 $k = \frac{20 \log m}{\epsilon^2}$ 时, 有:

$$\begin{aligned} \Pr\left[\bigcap_{1 \leq i < j \leq m} A_{ij}\right] &\geq 1 - (m-1)m/2 * 2m^{-(5-2.5)} \\ &\geq 1 - m^2 * 2m^{-2.5} \\ &\geq 1 - 2m^{-0.5} \\ &> 0 \end{aligned} \quad (101)$$

□